PRPrompt：面向少样本节点分类的原型路由图提示

摘要

本文提出原型路由图提示方法 PRPrompt，利用支持集原型将可学习提示分配给不同节点。在每类仅有少量标注的条件下，任务适配不仅需要学习提示内容，还需要确定提示应当作用于哪些节点。PRPrompt 从聚合节点属性构造类别参照，在保留支持集锚点的同时利用未标注图特征进行校正，并将节点与原型的关联转换为固定路由矩阵。该矩阵组合可学习类别提示，将其注入冻结图卷积编码器，最终采用原型分类。我们在 Cora、CiteSeer、PubMed 上分别评估 1、3、5-shot 设置，按原 ProG 实现抽样，支持与测试节点可能重叠；对各条件使用配对的任务与训练种子。5-shot 下，三个数据集的 Accuracy 分别为 72.87%、64.70%、68.34%；相对同配方共享提示，原型路由在对应条件下分别带来 36.57、39.09、3.34 个百分点的提升。这些逐条件配对结果支持原型关系对提示分配的组织价值，结论限于该含重叠的传导式评估协议。

1 引言

预训练图神经网络为标注稀缺条件下的节点分类提供了已有表示。图提示通过少量任务参数完成适配，具体形式包括特征修改、提示结构和任务读出 [3, 10, 14, 15]。除选择注入位置之外，适配方法还需要回答：提示的贡献应当如何分配给不同节点？同一图中的节点在下游分类任务中具有不同的角色，因此提示分配本身就是值得研究的设计问题。

共享提示表达全图一致的调整。更灵活的方法可以学习输入相关的组合、在子图层面分配提示，或通过策略选择被提示的节点 [3, 8, 22]。这些工作说明，节点相关的分配本身并非新概念。本文关注一个更具体的问题：任务已有的少量标注样本，能否直接定义有效的路由系数，使优化集中于提示内容？支持样本提供了当前任务的类别参照，这些参照可以在适配之前构造，无需额外训练路由网络。

基于这一问题，本文提出 PRPrompt，以支持集锚定的原型作为提示分配的任务坐标。类别关联相近的节点接收相关的类别提示组合。方法首先从聚合图属性构造路由表示，以标注支持节点初始化原型，并在保留支持锚点的条件下利用未标注特征校正原型。节点与原型的关联形成固定路由矩阵，在冻结 GCN 内部组合可学习提示向量。训练仅优化提示内容，最终采用原型分类。图 1 概括了固定分配与内容学习的分工。

实验围绕两个问题组织。首先，完整适配在本地配对运行中相对冻结预训练和全量微调表现如何，其 Accuracy 在文献报告的提示结果中处于什么位置？其次，在注入位置和训练配方固定时，原型路由能否提供超出共享提示的价值？正文报告 Cora、CiteSeer、PubMed 的 1、3、5-shot，另五个数据集见附录 D；外部 Accuracy 取自 Chen et al. [2]，保留其原始协议。每项结果均对应独立的数据集和 shot 数。相对冻结预训练，PubMed 上的收益明显小于 Cora 与 CiteSeer。

本文的主要贡献如下：

- 提出原型路由图提示构造，由支持集锚定的类别关系在提示优化前确定节点相关的分配方式。
- 给出包含 $C \times 128$ 个可学习提示参数的隐藏层实现，无需可学习路由网络。
- 提供配对适配比较与共享提示消融，逐条件报告 seed 波动及配对不确定性。

贡献聚焦原型关系对隐藏层提示的组织作用，不将原型或节点相关提示视为新的基本构件。

2 相关工作

图表示与预训练。 图卷积、邻域采样与图注意力提供了不同的节点表示构造方式 [4, 7, 16]。图自监督目标包括局部与全局信息最大化 [17]、基于增广的对比学习 [18] 以及掩码重建 [5]。预训练目标会影响下游迁移，联合节点级与图级目标也已有专门研究 [6]。本文固定每个图的预训练权重，研究下游适配，不提出新的预训练目标。

预训练与下游任务对齐。 GPPT 与 GraphPrompt 通过任务重构和提示连接预训练与下游预测 [10, 14]。All in One 通过提示向量、结构和插入规则处理多层级任务 [15]；MultiGPrompt 结合多个预训练任务及下游提示 [20]。HGPrompt 与 HetGPT 将提示学习拓展到异构图设置 [11, 19]。这些工作关注任务或图类型之间的对齐，本文则在少样本节点分类中研究更具体的问题：如何利用任务类别参照在节点间分配提示。

自适应提示分配。 GPF-plus 学习输入相关的提示组合 [3]，SUPT 在子图层面分配提示 [8]，RELIEF 联合学习节点选择与提示内容 [22]。ProNoG 面向非同配图研究条件化的节点专属提示 [21]，DAGPrompT 关注分布感知的图适配 [1]。属性引导的动态提示也已用于提升模型应对图扰动的鲁棒性 [9]。与学习分配函数的思路不同，PRPrompt 预先计算支持集条件下的原型关系，并在提示训练期间固定路由。上述工作用于界定设

计空间，并非全部纳入本文的实验比较。

类别原型与评估。 Prototypical Networks 利用支持集类别代表进行预测 [13]，半监督扩展则将未标注样本用于原型构造 [12]。本文利用这些已有思想构造路由的任务参照：路由原型位于聚合属性空间，预测原型来自适配后的编码器输出。ProG 强调评估协议的明确性 [23]。Chen et al. [2] 报告了不同预训练策略下的适配结果；本文引用其基线 Accuracy 作为文献参照，同时保留本地配对消融以检验路由价值。

3 问题定义

给定属性图 $G=(V,E,X)$，节点数为 n，特征矩阵为 $X\in\mathbb{R}^{n\times d}$，任务类别数为 C。每类支持集 S_c 的实际标注数记为 k_c，名义 shot 为 $k\in\{1,3,5\}$。正文三个数据集均满足 $k_c=k$；附录记录少数类别不足的情况。记 $S=\bigcup_c S_c$，T 为原 ProG 实现生成的测试集，允许 $S\cap T\neq\varnothing$。完整图结构与所有特征可见，拟合和选参接收 S 内标签；评分在预测保存后进行。重叠节点的标签已经参与训练，因此该指标并非严格未标注节点上的泛化成绩。

编码器采用预训练两层 GCN [7]，隐藏维度与输出维度均为 128，在 PRPrompt 中保持冻结。本文属于同图、已知类别的传导式分类：查询特征参与图聚合、原型校正和全图中心化，不属于归纳式未见类别评估。文中的一个实验条件固定数据集、shot 数、方法及预训练权重。

4 原型路由图提示

方法概览。 方法将分配与内容分开处理：首先，在聚合属性空间中用支持集锚定原型定义类别关系；其次，将这些关系转换为固定路由矩阵，为每个节点组合提示；最后，利用支持监督在冻结编码器内学习提示向量。以下各节依照这一计算顺序展开。

4.1 支持集锚定的类别参照

令 $\widehat{A}=\widetilde{D}^{-1/2}(A+I)\widetilde{D}^{-1/2}$ 为带自环的归一化邻接算子。由两跳聚合属性构造路由表示：

$$\begin{aligned}X^{(2)}&=\widehat{A}^2X,\\ R&=\mathrm{rownorm}\Big(X^{(2)}-\mathbf{1}\,\mathrm{mean}_{v\in V}\,X_v^{(2)}\Big).\end{aligned}\tag{1}$$

其中 rownorm 对每一行进行欧氏归一化。路由使用图属性及结构，不依赖额外学习的网络。类别初始参照为

$$\mu_c^{(0)}=\frac{1}{k_c}\sum_{i\in S_c}R_i.\tag{2}$$

为利用未标注图信息并保留标注参照，记 $U_V=V\setminus S$。从 $\mu^{(0)}$ 开始，令 $i\in U_V$、$t=0,1,2$，进行三轮固定校正：

$$a_{ic}^{(t)}=\frac{\exp(R_i^\top\,\mathrm{norm}\Big(\mu_c^{(t)}\Big)/0.05)}{\sum_{c'}\exp(R_i^\top\,\mathrm{norm}\Big(\mu_{c'}^{(t)}\Big)/0.05)},\tag{3}$$

$$\mu_c^{(t+1)}=0.5\mu_c^{(0)}+0.5\frac{\sum_{i\in U_V}a_{ic}^{(t)}R_i}{\max(\sum_{i\in U_V}a_{ic}^{(t)},10^{-8})}.\tag{4}$$

每轮锚点始终为最初的支持原型，而不是上一轮原型。这是固定的原型构造过程，本文不赋予其期望最大化目标或收敛保证。计算不使用 U_V 中节点的标签。

4.2 从类别关系到固定路由

以校正后的原型计算温度为 $\tau_r=0.1$ 的节点—类别关联：

$$\begin{aligned}Q_{ic}&=\mathrm{softmax}_c\Big(R_i^\top\,\mathrm{norm}\Big(\mu_c^{(3)}\Big)/\tau_r\Big),\\ B&=\widehat{A}\,(Q-\mathbf{1}\,\mathrm{mean}_{v\in V}\,Q_v).\end{aligned}\tag{5}$$

中心化表示节点类别关联相对全图平均关联的偏离，邻域聚合进一步整合相邻节点的关联模式。Q 是按行归一化的关联矩阵，B 则包含可为负的提示组合系数，不能解释为最终类别概率。每个支持集仅计算一次 B，提示训练期间保持不变。

4.3 冻结隐藏计算中的提示适配

令 H^{pre} 为原图经过 GCN 第一层得到的预激活表示，学习零初始化的矩阵 $P\in\mathbb{R}^{C\times 128}$。记 s 为 H^{pre} 的逐通道样本标准差，下界设为 10^{-6}，则注入后的隐藏表示为

$$\widetilde{H}^{\mathrm{pre}}=H^{\mathrm{pre}}+10\,[B\tanh(P)]\odot s.\tag{6}$$

尺度向量按节点广播。经过原有 LeakyReLU 与第二层图卷积后得到 Z。支持监督优化提示内容，路由与编码器参数保持固定；零初始化使训练起点恢复冻结编码器的原始计算。Cora、CiteSeer、PubMed 分别包含 896、768、384 个可学习提示参数。

4.4 训练与预测

使用 Adam 优化提示矩阵 100 步，学习率为 0.01，权重衰减为 0：

$$\begin{aligned}\mathcal{L}(P)=\frac{1}{|S|}\sum_{i\in S}\mathrm{CE}(\ell_i(P),y_i)\\ +10^{-3}\,\mathrm{mean}(P\odot P).\end{aligned}\tag{7}$$

支持 logits ℓ_i 采用余弦原型分类，路由消融始终使用相同的原型读出。支持集留一构造、预测归一化及温度等复现细节统一放在附录 A。

路由只需预先计算一次。在稀疏图上，两次属性聚合的复杂度为 $O(|E|d)$，每轮原型校正为 $O(nCd)$，每步提示组合 $B\tanh(P)$ 为 $O(nC\cdot 128)$，此外还包含冻结

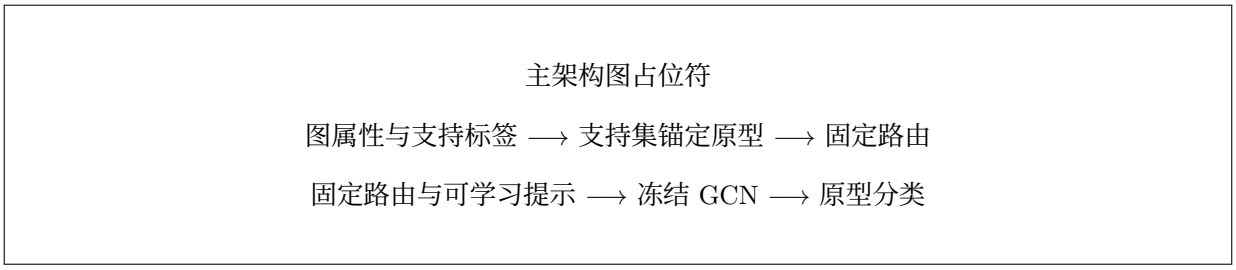


图 1: PRPrompt 总体流程。支持标签在聚合属性空间中初始化类别参照，未标注图特征用于校正参照，节点与原型的关联决定固定路由矩阵。仅类别提示向量参与优化，路由后的提示注入冻结 GCN 的第一隐藏层。拟合与选参只使用支持标签，其中包含原 ProG 划分下与测试集重叠的节点。主架构图按要求暂用占位符。

编码器的前向与反向计算。冻结权重减少可学习参数，但不会消除经过第二层卷积的梯度计算。因此本文报告参数量，不声称未经测量的运行时间优势。

5 实验

5.1 协议与比较方法

本轮复算覆盖八个数据集，正文展示 Cora、CiteSeer、PubMed，其余结果见附录 D。划分复用原 ProG 的两次独立随机排列：第一次前 90% 节点构成测试集，第二次后 10% 构成支持候选池，再按类取前 k 个并打乱支持顺序。每个条件包含 20 个任务 seed 与 3 个训练 seed；每次任务重建划分，同一任务内各方法的支持／测试身份一致，shot 支持集合嵌套。所有方法复用先前固定的边预测预训练权重，未重新预训练。支持／测试重叠是本次原实现口径的一部分，重叠数完整记录。

本地对照包含：**冻结预训练**，不添加提示并采用与 PRPrompt 相同的最终原型读出；**全量微调**，更新预训练编码器及任务读出。提示基线 Accuracy 引用 Chen et al. [2] 表 4–6 中的 GPPT、Gprompt（GraphPrompt）、All-in-one、GPF、GPF-plus，并保留原表的监督学习与微调参照，排除其 MTG 方法。原文基线结合 ProG 结果与作者复现，报告不同预训练策略中的最佳表现，但未给出各单元对应的具体策略。

文献协议。 来源论文使用 90% 测试集、5 次任务抽样与随机超参数搜索，主要编码器为两层、隐藏维度 128 的 GCN。本轮对齐原 ProG 的划分实现，但未取得来源论文的具体节点划分；不能据上游实现推断其实际重叠情况。checkpoint、选参和重复次数仍不匹配，因此表 1分为文献与本地两个面板，保留文献原始数值，不跨面板配对或统一排名。文献表仅提供 Accuracy，其他指标来自本地运行。

PRPrompt 与共享提示消融使用同一固定配方。本地全量微调在 3-shot 和 5-shot 下使用三个支持内折，候选为学习率 $\{0.001, 0.01\}$ 与权重衰减 $\{0, 0.0001\}$ 的四种组合。各候选拟合及最终拟合均为 100 步；1-shot 使用固定参数。因此，本地方法的总优化预算并不完全相同，其余设置见附录 A。

统计单位。 在固定本地条件内，先对同一任务抽样下的 3 个训练 seed 求均值，再对 20 个任务抽样结果计算均值与样本标准差。不跨数据集或 shot 汇总平均表现。本地配对区间以任务抽样为块进行 10,000 次 bootstrap，报告固定图和权重条件下、未经多重比较校正的 95% 区间，仅用于冻结预训练、全量微调及共享提示对照。正文报告 Accuracy 与 Macro-F1，其余本地指标见附录 B。

5.2 RQ1：完整适配的效果

本地比较检验相同图、权重及支持标签预算下的适配效果。表 1 另外加入独立协议的文献参照；表 2 报告本地 Macro-F1。每列均为独立条件，不包含跨条件平均行。

Cora 的 5-shot Accuracy 为 72.87%，冻结预训练与全量微调分别为 35.16% 和 66.12%；CiteSeer 在相同 shot 数下分别为 64.70%、27.52%、49.92%。PubMed 的冻结预训练更强：5-shot 为 65.68%，PRPrompt 为 68.34%，全量微调为 64.14%。因此，相对冻结预训练的改善在 PubMed 上明显较小，跨数据集平均会掩盖这一依赖关系。

文献报告的提示结果。 引入文献数据后，不能声称 Accuracy 全面领先。CiteSeer 上 GPF-plus 在 1、3、5-shot 分别报告 59.67%、72.48%、75.73%，本地 PRPrompt 对应为 43.92%、59.67%、64.70%。Cora 的 5-shot 本地结果 72.87% 高于文献 Gprompt 的 69.03%；PubMed 的 3-shot 本地结果 65.09% 低于文献 GPF 的 71.20%。这些属于跨来源的描述性比较，不是匹配协议下的方法效应估计。路由价值由下述本地消融支持，本地配对差值见附录 C。

5.3 RQ2：原型路由的价值

核心消融将式 (6) 的 B 替换为元素均为 $1/C$ 的常数矩阵，保留提示矩阵、尺度、注入位置、优化与最终读出，移除节点相关的提示分配。常数矩阵直接用于组合，不再中心化，否则提示会被完全消除；同时保留无提示的冻结预训练条件。

表 3 表明，单纯学习共享提示不足以解释完整方法的收益。5-shot 下，原型路由相对共享提示在 Cora、

表 1: 少样本节点分类的 Accuracy。越高越好（↑）。

方法	Cora			CiteSeer			PubMed		
	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot
文献报告基线 *[2]*									
Supervised	26.56± 5.55	37.79± 9.16	50.25± 8.37	21.78± 7.32	35.18± 6.86	41.22± 6.30	39.37± 16.34	57.33± 4.64	67.88± 2.18
Fine-tuning	52.61± 1.73	51.97± 2.84	62.66± 3.55	35.05± 4.37	45.08± 2.09	39.54± 3.54	46.74± 14.89	65.40± 3.00	**70.91**± 4.87
GPPT	43.15± 9.44	43.84± 6.11	51.98± 3.43	37.26± 6.17	42.34± 8.31	45.77± 7.41	48.31± 17.72	67.43± 2.96	66.97± 3.70
Gprompt	**56.66**± 11.22	**63.78**± 5.77	**69.03**± 3.61	53.21± 10.94	60.00± 6.18	66.13± 1.64	39.74± 15.35	66.68± 3.53	67.87± 2.08
All-in-one	52.39± 10.17	48.09± 4.83	30.36± 13.48	40.41± 2.80	48.09± 8.18	27.93± 10.59	45.17± 6.45	65.79± 5.79	46.16± 15.83
GPF	38.57± 5.41	34.84± 19.83	35.43± 1.02	31.16± 8.05	25.92± 12.30	25.12± 3.01	**49.99**± 8.86	**71.20**± 2.82	68.96± 3.99
GPF-plus	55.77± 10.30	56.38± 5.37	66.22± 6.20	**59.67**± 11.87	**72.48**± 5.63	**75.73**± 2.19	46.64± 18.97	70.85± 4.03	69.59± 4.33
本地测量（协议不同）									
冻结预训练	24.64± 4.63	30.86± 3.27	35.16± 2.40	21.69± 3.47	24.96± 3.51	27.52± 3.72	53.72± 10.60	62.49± 9.18	65.68± 5.56
全量微调	45.15± 8.56	59.29± 6.26	66.12± 5.09	33.59± 5.82	42.05± 6.91	49.92± 5.85	49.90± 8.69	58.72± 8.45	64.14± 7.08
PRPrompt	**53.80**± 8.45	**69.97**± 3.53	**72.87**± 3.36	**43.92**± 11.01	**59.67**± 5.98	**64.70**± 3.53	**59.77**± 7.47	**65.09**± 8.21	**68.34**± 6.97

均值 ± 标准差（%）。文献：Chen et al. [2]表 4–6，5 次抽样、跨预训练策略最佳报告值。本地：旧 checkpoint、原 ProG 抽样（90% 测试；独立抽取支持池，保留重叠）；先平均每任务 3 个训练 seed，再统计 20 个任务。**粗体**／下划线 仅为同面板同列最优／次优。文献具体划分未知，其他设置不一致，不跨来源配对或求平均。

表 2: 少样本节点分类的 Macro-F1。越高越好（↑）。

方法	Cora			CiteSeer			PubMed		
	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot
冻结预训练	23.79± 4.61	30.11± 2.90	34.48± 2.30	20.84± 3.15	23.85± 3.32	26.11± 3.34	52.29± 9.78	61.43± 9.05	64.19± 5.48
全量微调	42.44± 7.83	58.11± 6.07	65.62± 4.62	28.52± 6.08	37.21± 6.65	45.91± 5.39	46.50± 9.40	56.26± 10.15	61.97± 8.12
PRPrompt	**51.82**± 7.47	**68.37**± 4.08	**72.02**± 2.74	**41.48**± 10.31	**56.34**± 5.54	**61.34**± 3.09	**59.39**± 7.93	**64.82**± 8.80	**67.80**± 7.59

本地原 ProG 实现，保留支持／测试重叠：先平均每任务 3 个训练 seed，再报告 20 个任务的均值 ± 样本标准差。**粗体**／下划线 表示同条件最优／次优；不跨条件平均。文献表 4–6 未报告这些基线的本指标。

CiteSeer、PubMed 的 Accuracy 分别提高 36.57、39.09、3.34 个百分点，对应配对 95% 区间为 $[34.82, 38.17]$、$[37.37, 40.84]$、$[1.03, 5.50]$ 个百分点。在各个 1-shot 和 3-shot 条件中，两项主要指标的配对改善也均为正。

该比较支持完整原型路由构造相对共享提示的作用，不能将收益单独归因于原型校正、中心化或图聚合中的某一步。均匀组合虽然保留名义提示参数量，却降低有效自由度，因此也不能视为完全控制容量后对唯一路由机制的证明。

6 局限性

正文聚焦三个引文网络，附录扩展到五个数据集；各图使用一份既有 checkpoint，不估计预训练运行之间的波动。本轮数据集范围在复算前确定，但模型已在这些图上开发，因此仍属描述性分析。原 ProG 实现允许支持／测试重叠，指标包含部分已标注节点，不能作为严格未标注泛化的证据。ogbn-arxiv 部分名义 3/5-shot 任务还存在类别支持不足。这些边界限制了对图分类、未见类别和任意预训练来源的推广。

文献基线的具体划分身份未知，且采用 5 次抽样及跨预训练策略选择，其汇总值可提供参照，但不能相对本地固定权重运行隔离适配方法的影响，也不支持配对显著性检验。本地微调选参产生的预算也不同于 PRPrompt 的固定配方。路由消融改变了有效提示容量，未区分路由内部各步骤的贡献。此外，方法利用查询特征和全图统计，缺少这类传导式信息的部署条件需另行评估。

7 结论

PRPrompt 利用支持集锚定的原型组织冻结图编码器内的提示分配。三个正文数据集的同协议消融支持其相对共享提示的价值；扩展实验同时呈现微调优势与弱效应条件。该结论限于本次原 ProG 实现评估，支持／测试重叠使其不能替代严格未标注节点上的验证。

潜在影响

本文研究公开图节点分类基准，不评估涉及个人的实际决策。图聚合与未标注原型校正可能传播错误，尤其当图结构或类别结构偏离所评估设置时。涉及重要后果的应用需要开展基准之外的领域评估。

表 3: 原型路由消融。提示训练配方与读出保持一致。

方法	Cora			CiteSeer			PubMed		
	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot
Accuracy (%) ↑									
冻结预训练	24.64± 4.63	30.86± 3.27	35.16± 2.40	21.69± 3.47	24.96± 3.51	27.52± 3.72	53.72± 10.60	62.49± 9.18	65.68± 5.56
共享提示	24.15± 4.41	31.25± 3.68	36.30± 2.72	20.64± 3.07	23.71± 3.88	25.60± 3.82	52.61± 10.70	60.89± 9.03	65.00± 5.72
PRPrompt	**53.80**± 8.45	**69.97**± 3.53	**72.87**± 3.36	**43.92**± 11.01	**59.67**± 5.98	**64.70**± 3.53	**59.77**± 7.47	**65.09**± 8.21	**68.34**± 6.97
Macro-F1 (%) ↑									
冻结预训练	23.79± 4.61	30.11± 2.90	34.48± 2.30	20.84± 3.15	23.85± 3.32	26.11± 3.34	52.29± 9.78	61.43± 9.05	64.19± 5.48
共享提示	22.78± 4.10	30.03± 3.70	34.69± 2.61	19.75± 2.74	22.28± 3.34	24.42± 3.38	51.98± 10.37	59.21± 10.06	63.59± 6.09
PRPrompt	**51.82**± 7.47	**68.37**± 4.08	**72.02**± 2.74	**41.48**± 10.31	**56.34**± 5.54	**61.34**± 3.09	**59.39**± 7.93	**64.82**± 8.80	**67.80**± 7.59

本地原 ProG 实现，保留支持／测试重叠：先平均每任务 3 个训练 seed，再报告 20 个任务的均值 ± 样本标准差。**粗体**／下划线 表示同条件最优／次优；不跨条件平均。冻结预训练：无提示；共享提示：均匀分配；PRPrompt：原型路由。

参考文献

[1] Q. Chen, L. Wang, B. Zheng, and G. Song. DAGPrompT: Pushing the Limits of Graph Prompting with a Distribution-aware Graph Prompt Tuning Approach. In *Proceedings of the ACM on Web Conference 2025*, WWW '25, pages 4346–4358. ACM, Apr. 2025. doi: 10.1145/3696410.3714917. URL http://dx.doi.org/10.1145/3696410.3714917.

[2] Y. Chen, D. Ma, S. Zhang, Y. Liu, X. Lin, X. Zhao, W. Yang, W. Chen, and C. Zhou. Message Tuning Outshines Graph Prompt Tuning: A Prismatic Space Perspective. In T. Zhang, M. Dudik, M. Jaggi, A. Agarwal, S. Li, D. Schuurmans, J. Zhu, F. Berkenkamp, H. Dong, and A. Bietti, editors, *Proceedings of the 43rd International Conference on Machine Learning*, volume 306 of *Proceedings of Machine Learning Research*, pages 16063–16104. PMLR, 06–11 Jul 2026. URL https://proceedings.mlr.press/v306/chen26cz.html.

[3] T. Fang, Y. Zhang, Y. Yang, C. Wang, and L. Chen. Universal Prompt Tuning for Graph Neural Networks. In A. Oh, T. Naumann, A. Globerson, K. Saenko, M. Hardt, and S. Levine, editors, *Advances in Neural Information Processing Systems*, volume 36, pages 52464–52489. Curran Associates, Inc., 2023. doi: 10.52202/075280-2285. URL https://proceedings.neurips.cc/paper_files/paper/2023/file/a4a1ee071ce0fe63b83bce507c9dc4d7-Paper-Conference.pdf.

[4] W. Hamilton, Z. Ying, and J. Leskovec. Inductive Representation Learning on Large Graphs. In I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, volume 30. Curran Associates, Inc., 2017. URL https://proceedings.neurips.cc/paper_files/paper/2017/file/5dd9db5e033da9c6fb5ba83c7a7ebea9-Paper.pdf.

[5] Z. Hou, X. Liu, Y. Cen, Y. Dong, H. Yang, C. Wang, and J. Tang. GraphMAE: Self-Supervised Masked Graph Autoencoders. In *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, KDD '22, pages 594–604. ACM, Aug. 2022. doi: 10.1145/3534678.3539321. URL http://dx.doi.org/10.1145/3534678.3539321.

[6] W. Hu, B. Liu, J. Gomes, M. Zitnik, P. Liang, V. Pande, and J. Leskovec. Strategies for Pre-training Graph Neural Networks. In *International Conference on Learning Representations*, 2020. URL https://openreview.net/forum?id=HJlWWJSFDH.

[7] T. N. Kipf and M. Welling. Semi-Supervised Classification with Graph Convolutional Networks. In *International Conference on Learning Representations (ICLR)*, 2017.

[8] J. Lee, W. Yang, and J. Kang. Subgraph-level universal prompt tuning. *Information Sciences*, 749:123516, Sept. 2026. ISSN 0020-0255. doi: 10.1016/j.ins.2026.123516. URL http://dx.doi.org/10.1016/j.ins.2026.123516.

[9] Z. Liang, L. Bai, and X. Yang. Attribute-guided Dynamic Prompt Learning for Graph Neural Networks. *Proceedings of the AAAI Conference on Artificial Intelligence*, 40(28): 23442–23450, Mar. 2026. ISSN 2159-5399. doi: 10.1609/aaai.v40i28.39515. URL http://dx.doi.org/10.1609/aaai.v40i28.39515.

[10] Z. Liu, X. Yu, Y. Fang, and X. Zhang. GraphPrompt: Unifying Pre-Training and Downstream Tasks for Graph Neural Networks. In *Proceedings of the ACM Web Conference 2023*, WWW '23, pages 417–428. ACM, Apr. 2023. doi: 10.1145/3543507.3583386. URL http://dx.doi.org/10.1145/3543507.3583386.

[11] Y. Ma, N. Yan, J. Li, M. Mortazavi, and N. V. Chawla. HetGPT: Harnessing the Power of Prompt Tuning in Pre-Trained Heterogeneous Graph Neural Networks. In *Proceedings of the ACM Web Conference 2024*, WWW '24, pages 1015–1023. ACM, May 2024. doi: 10.1145/3589334.3645685. URL http://dx.doi.org/10.1145/3589334.3645685.

[12] M. Ren, E. Triantafillou, S. Ravi, J. Snell, K. Swersky, J. B. Tenenbaum, H. Larochelle, and R. S. Zemel. Meta-Learning for Semi-Supervised Few-Shot Classification, 2018. URL https://arxiv.org/abs/1803.00676.

[13] J. Snell, K. Swersky, and R. Zemel. Prototypical Networks for Few-shot Learning. In I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, volume 30. Curran Associates, Inc., 2017. URL https://proceedings.neurips.cc/paper_files/paper/2017/file/cb8da6767461f2812ae4290eac7cbc42-Paper.pdf.

[14] M. Sun, K. Zhou, X. He, Y. Wang, and X. Wang. GPPT: Graph Pre-training and Prompt Tuning to Generalize Graph Neural Networks. In *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data*

Mining, KDD '22, pages 1717–1727. ACM, Aug. 2022. doi: 10.1145/3534678.3539249. URL http://dx.doi.org/10.1145/3534678.3539249.

[15] X. Sun, H. Cheng, J. Li, B. Liu, and J. Guan. All in One: Multi-Task Prompting for Graph Neural Networks. In *Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, KDD '23, pages 2120–2131. ACM, Aug. 2023. doi: 10.1145/3580305.3599256. URL http://dx.doi.org/10.1145/3580305.3599256.

[16] P. Veličković, G. Cucurull, A. Casanova, A. Romero, P. Liò, and Y. Bengio. Graph Attention Networks. *International Conference on Learning Representations*, 2018. URL https://openreview.net/forum?id=rJXMpikCZ. accepted as poster.

[17] P. Veličković, W. Fedus, W. L. Hamilton, P. Liò, Y. Bengio, and R. D. Hjelm. Deep Graph Infomax. In *International Conference on Learning Representations*, 2019. URL https://openreview.net/forum?id=rklz9iAcKQ.

[18] Y. You, T. Chen, Y. Sui, T. Chen, Z. Wang, and Y. Shen. Graph Contrastive Learning with Augmentations. In H. Larochelle, M. Ranzato, R. Hadsell, M. Balcan, and H. Lin, editors, *Advances in Neural Information Processing Systems*, volume 33, pages 5812–5823. Curran Associates, Inc., 2020. URL https://proceedings.neurips.cc/paper_files/paper/2020/file/3fe230348e9a12c13120749e3f9fa4cd-Paper.pdf.

[19] X. Yu, Y. Fang, Z. Liu, and X. Zhang. HGPrompt: Bridging Homogeneous and Heterogeneous Graphs for Few-Shot Prompt Learning. *Proceedings of the AAAI Conference on Artificial Intelligence*, 38(15):16578–16586, Mar. 2024. ISSN 2159-5399. doi: 10.1609/aaai.v38i15.29596. URL http://dx.doi.org/10.1609/aaai.v38i15.29596.

[20] X. Yu, C. Zhou, Y. Fang, and X. Zhang. MultiGPrompt for Multi-Task Pre-Training and Prompting on Graphs. In *Proceedings of the ACM Web Conference 2024*, WWW '24, pages 515–526. ACM, May 2024. doi: 10.1145/3589334.3645423. URL http://dx.doi.org/10.1145/3589334.3645423.

[21] X. Yu, J. Zhang, Y. Fang, and R. Jiang. Non-Homophilic Graph Pre-Training and Prompt Learning. In *Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining V.1*, KDD '25, pages 1844–1854. ACM, July 2025. doi: 10.1145/3690624.3709219. URL http://dx.doi.org/10.1145/3690624.3709219.

[22] J. Zhu, Z. Ding, J. Yu, J. Tan, X. Li, and W. Qian. RELIEF: Reinforcement Learning Empowered Graph Feature Prompt Tuning. In *Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining V.1*, KDD '25, pages 2159–2170. ACM, July 2025. doi: 10.1145/3690624.3709252. URL http://dx.doi.org/10.1145/3690624.3709252.

[23] C. Zi, H. Zhao, X. Sun, Y. Lin, H. Cheng, and J. Li. ProG: A Graph Prompt Learning Benchmark. In A. Globerson, L. Mackey, D. Belgrave, A. Fan, U. Paquet, J. Tomczak, and C. Zhang, editors, *Advances in Neural Information Processing Systems*, volume 37, pages 95406–95437. Curran Associates, Inc., 2024. doi: 10.52202/079017-3023. URL https://proceedings.neurips.cc/paper_files/paper/2024/file/ad3e803a977f4279330c6ab7245937c6-Paper-Datasets_and_Benchmarks_Track.pdf.

A 实现与可复现细节

A.1 图预处理与固定权重

表 4给出正文数据维度。沿用既有图张量及预处理，不再使用官方训练／测试掩码；每个任务按原 ProG 的两次独立排列生成 90% 测试集和 10% 候选池。支持节点从候选池逐类取前 k 个，剩余节点作为未标注上下文。支持／测试集合可能重叠，实际索引及重叠数保存在结果包中。

表 4: 数据集规模与提示参数量。

数据集	节点	特征	类别	提示参数
Cora	2,708	1,433	7	896
CiteSeer	3,327	3,703	6	768
PubMed	19,717	500	3	384

编码器由两层宽度为 128 的 GCNConv 构成，中间使用 LeakyReLU。第一层包含预训练仿射变换与图聚合，提示添加在该层输出、非线性激活之前；第二层卷积在所评估编码器中不再接额外激活。每个数据集的所有方法使用相同权重，准备阶段确认 checkpoint 版本，结果包保留任务索引。预训练来源标识为 `Edgepred_Gprompt`，预训练随机种子未记录。

A.2 训练与预测细节

正文描述实际生效的前向计算。Adam 使用 $\beta_1 = 0.9$、$\beta_2 = 0.999$、$\epsilon = 10^{-8}$，学习率为 0.01，权重衰减为 0。提示正则为提示矩阵元素平方的均值乘以 10^{-3}，与优化器权重衰减不同。逐通道尺度使用分母为 $n-1$ 的样本标准差；欧氏归一化采用实现中的 10^{-12} 范数下界。没有蒸馏或额外测试标签目标；重叠测试节点作为支持节点参与监督。

对于支持损失，令 $\bar{z}_i = \mathrm{norm}(Z_i)$，$m_c = \sum_{j \in S_c} \bar{z}_j$。当 $\min_c k_c > 1$ 时，支持节点 i 的训练原型为

$$
\begin{aligned}
p_c^{(-i)} &= \mathrm{norm}\left(\frac{m_c - \mathbb{I}[y_i = c]\bar{z}_i}{k_c - \mathbb{I}[y_i = c]} \right), \\
\ell_{ic} &= \bar{z}_i^{\top} p_c^{(-i)} / 0.2.
\end{aligned}
\tag{8}
$$

$\min_c k_c = 1$ 时，以包含自身的类别原型 $\mathrm{norm}(m_c/k_c)$ 替代 $p_c^{(-i)}$。预测时定义

$$
\begin{aligned}
z_i^* &= \mathrm{norm}\left(Z_i - \frac{1}{n} \sum_{j \in V} Z_j \right), \\
p_c^* &= \mathrm{norm}\left(\frac{1}{k_c} \sum_{i \in S_c} z_i^* \right), \\
\widehat{y}_i &= \arg\max_c (z_i^*)^{\top} p_c^*.
\end{aligned}
\tag{9}
$$

将余弦 logits 除以 0.2 后取 softmax，得到五项指标使用的概率分数。训练时不使用预测阶段的输出中心化。读出是固定实现选择，不是本文的实验比较因素。

计算流程。 给定图、固定预训练权重及支持标签：

1. 归一化邻接，计算式 (1) 及第一层预激活表示。
2. 依式 (2) 初始化支持原型，执行式 (3)–(4) 三轮。
3. 依式 (5) 计算固定路由；共享提示消融则将其替换为 $B_{ic} = 1/C$。
4. 初始化 $P = 0$ 并缓存隐藏通道尺度，固定编码器与路由。

5. 重复 100 步：运行提示编码器，构造支持 logits，依式 (7) 更新 P。
6. 依式 (9) 计算最终原型分数，封存预测后再使用查询标签评分。

A.3 基线拟合与随机种子

任务 seed 为 30093000 至 30093019，训练 seed 为 0、1、2。每个任务先生成测试集，再独立生成支持候选池，按类取前 k 个并打乱支持顺序。各方法的任务索引相同，1/3/5-shot 支持集合嵌套。候选不足时保留实际 $k_c < k$，不补抽样。冻结预训练保留三个 seed 槽位以对齐记录，不能解释为三次独立拟合。

本地全量微调使用支持交叉熵与任务读出，最小类别支持数为 1 时的固定参数为学习率 0.01、权重衰减 0.0001。实际最小类别支持数大于 1 时，使用 $\min(3, \min_c k_c)$ 个支持内折，各留出每类一个节点，按留出支持交叉熵均值选择四种候选配置，再在完整支持集上重新拟合；不使用额外验证标签预算。该本地协议控制标注信息与最终训练步数，但总选参计算量或读出参数化并不完全一致，也不适用于导入的文献基线。

A.4 同一条件内的统计

固定数据集、shot 数、预训练权重和方法，以 a_{st} 表示支持 seed s、训练 seed t 的某项指标，计算

$$\bar{a}_s = \frac{1}{3}\sum_{t=1}^{3} a_{st}, \qquad \widehat{a} = \frac{1}{20}\sum_{s=1}^{20} \bar{a}_s,$$
$$\widehat{\sigma} = \sqrt{\frac{1}{19}\sum_{s=1}^{20} (\bar{a}_s - \widehat{a})^2}. \tag{10}$$

本地单元报告 $100\widehat{a} \pm 100\widehat{\sigma}$，不是标准误。本地配对比较对 $d_s = \bar{a}_s^{\mathrm{PRPrompt}} - \bar{a}_s^{\mathrm{reference}}$ 按任务抽样块重采样，以 10,000 次重采样均值的百分位点构成 95% 区间，本轮按该规则重新计算全部区间。文献单元保留来源中的五次抽样均值与标准差，不套用式 (10)。不跨数据集、shot、方法或数据来源计算指标均值与平均效应。

数据包保留 Accuracy、Macro-F1、Micro-F1、宏平均 one-vs-rest ROC-AUC 和宏平均 AP。单标签多分类下 Micro-F1 与 Accuracy 相同，此处为完整性一并列出。不同任务重新抽取支持与测试集；区间反映固定图条件下任务抽样与训练波动，并非独立图样本的不确定性。

A.5 环境、来源与数值复核

复用 ProG 环境及既有图／权重，使用 PyTorch 2.11.0+cu130。逐单元记录拟合时间；并发任务的墙钟时间不用于推断方法效率优势。

本轮八个数据集共完成 5760 个正式单元，另有 96 个两步 smoke 单元，不计入正式统计。本地核验覆盖任务数、有限指标、配对支持／测试索引以及均值、标准差和 bootstrap 区间重算。保存表示读出采用 2×10^{-6} 容差；旧滤波器行和的严格浮点断言改为误差记录，运算未改。未重复执行逐文件哈希扫描或全新 CUDA 前向逐位审计，也不将旧版数值审计作为本轮证据。

外部 Accuracy 转录自 Chen et al. [2] 表 4–6（arXiv:2606.03290v1 的 PDF 第 37–38 页），记录保留表号、页码、原始小数、来源链接与 PDF 哈希。排除 MTG 后，共记录 147 个节点分类单元，论文使用其中三个数据集的 63 个单元。来源表结合 ProG 结果与作者复现，未逐单元标注来源归属或选中的预训练策略。导入记录不含原始预测，因此不计算外部配对检验。历史本地提示结果保留归档，不用于填补文献缺失指标。

代码与结果见 https://github.com/Mes-sala/PRPrompt，运行脚本位于 `experiments/prog_split_20261002`。本轮新增的是原 ProG 划分下的适配复算及其统计，没有重新预训练。前七个数据集沿用原始 Edgepred_Gprompt checkpoint，预训练 seed 未知；ogbn-arxiv 沿用此前全图边预测 checkpoint，预训练 seed 为 42。权重、图快照与模型状态留在服务器，本地只保留代码、预测结果、划分、表格与文档。

B 其余逐条件指标

以下表格按相同 seed 统计口径补充主比较的其余指标，每一列仍对应独立的数据集／ shot 条件。

表 5: 少样本节点分类的 Micro-F1。越高越好（↑）。

方法	Cora			CiteSeer			PubMed		
	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot
冻结预训练	24.64± 4.63	30.86± 3.27	35.16± 2.40	21.69± 3.47	24.96± 3.51	27.52± 3.72	53.72± 10.60	62.49± 9.18	65.68± 5.56
全量微调	45.15± 8.56	59.29± 6.26	66.12± 5.09	33.59± 5.82	42.05± 6.91	49.92± 5.85	49.90± 8.69	58.72± 8.45	64.14± 7.08
PRPrompt	**53.80**± 8.45	**69.97**± 3.53	**72.87**± 3.36	**43.92**± 11.01	**59.67**± 5.98	**64.70**± 3.53	**59.77**± 7.47	**65.09**± 8.21	**68.34**± 6.97

本地原 ProG 实现，保留支持／测试重叠：先平均每任务 3 个训练 seed，再报告 20 个任务的均值 ± 样本标准差。**粗体**／下划线 表示同条件最优／次优；不跨条件平均。文献表 4–6 未报告这些基线的本指标。

表 6: 少样本节点分类的 Macro ROC-AUC。越高越好（↑）。

方法	Cora			CiteSeer			PubMed		
	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot
冻结预训练	63.21± 4.73	69.93± 2.36	73.21± 2.16	56.08± 3.35	59.27± 3.49	61.37± 2.97	71.26± 10.76	80.38± 8.27	83.07± 4.42
全量微调	79.66± 4.17	88.47± 3.03	91.72± 2.18	69.34± 5.25	74.01± 3.87	78.59± 3.00	71.68± 7.97	79.93± 5.25	**83.87**± 4.51
PRPrompt	**81.14**± 5.37	**90.82**± 2.12	**92.22**± 1.34	**72.42**± 7.93	**82.11**± 2.86	**84.12**± 2.17	**77.21**± 6.53	**81.72**± 7.67	83.84± 5.88

本地原 ProG 实现，保留支持／测试重叠：先平均每任务 3 个训练 seed，再报告 20 个任务的均值 ± 样本标准差。**粗体**／下划线 表示同条件最优／次优；不跨条件平均。文献表 4–6 未报告这些基线的本指标。

表 7: 少样本节点分类的 Macro AP。越高越好（↑）。

方法	Cora			CiteSeer			PubMed		
	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot
冻结预训练	24.76± 4.19	30.07± 2.96	34.33± 2.50	21.33± 2.42	23.68± 2.88	25.30± 3.00	55.51± 10.07	66.73± 9.18	68.93± 6.61
全量微调	50.83± 7.37	67.63± 5.63	75.34± 4.11	36.52± 6.95	43.52± 6.52	50.83± 5.30	56.10± 9.47	66.58± 7.45	**72.23**± 6.16
PRPrompt	**56.27**± 8.10	**74.43**± 4.49	**78.20**± 2.98	**42.17**± 10.92	**57.10**± 5.18	**61.42**± 3.29	**61.55**± 8.90	**68.29**± 9.31	70.78± 8.65

本地原 ProG 实现，保留支持／测试重叠：先平均每任务 3 个训练 seed，再报告 20 个任务的均值 ± 样本标准差。**粗体**／下划线 表示同条件最优／次优；不跨条件平均。文献表 4–6 未报告这些基线的本指标。

C 配对差值与不确定性

各单元格报告 PRPrompt 减去本地对照的差值，单位为百分点，并附未经多重比较校正的 95% 配对任务 bootstrap 区间。所有数值保留原配对记录。文献基线没有配对运行，因此不列入本表；表格只组织条件，不对其求平均。

表 8: PRPrompt 的 Accuracy 配对增益。差值单位为百分点。

对照方法	Cora			CiteSeer			PubMed		
	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot
冻结预训练	+29.16 [25.55, 32.58]	+39.11 [37.04, 40.76]	+37.72 [36.15, 39.08]	+22.23 [18.15, 26.00]	+34.70 [32.66, 36.60]	+37.18 [35.66, 38.74]	+6.05 [1.54, 10.63]	+2.61 [-2.17, 6.99]	+2.66 [-0.33, 5.15]
全量微调	+8.64 [6.74, 10.55]	+10.68 [8.82, 12.81]	+6.75 [5.24, 8.27]	+10.33 [7.68, 12.85]	+17.61 [15.55, 19.53]	+14.78 [12.47, 17.05]	+9.87 [7.35, 12.44]	+6.37 [2.84, 10.10]	+4.20 [1.43, 7.07]
共享提示	+29.65 [26.14, 32.91]	+38.72 [36.85, 40.43]	+36.57 [34.82, 38.17]	+23.27 [19.38, 27.21]	+35.96 [33.80, 38.08]	+39.09 [37.37, 40.84]	+7.16 [2.85, 11.74]	+4.20 [0.77, 8.15]	+3.34 [1.03, 5.50]

上行为 PRPrompt 减去对照，下行为本轮重新计算、未经多重比较校正的 95% 配对任务 bootstrap 区间。保留支持／测试重叠。

表 9: PRPrompt 的 Macro-F1 配对增益。差值单位为百分点。

对照方法	Cora			CiteSeer			PubMed		
	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot
冻结预训练	+28.02 [24.70, 31.23]	+38.26 [36.09, 40.03]	+37.53 [36.21, 38.79]	+20.64 [16.82, 24.26]	+32.48 [30.52, 34.29]	+35.23 [33.82, 36.64]	+7.10 [2.43, 11.61]	+3.39 [-1.69, 7.90]	+3.60 [0.43, 6.17]
全量微调	+9.38 [7.57, 11.12]	+10.26 [8.42, 12.40]	+6.39 [4.85, 7.92]	+12.96 [10.44, 15.41]	+19.13 [17.02, 21.23]	+15.42 [13.31, 17.53]	+12.88 [9.62, 16.15]	+8.56 [4.78, 12.71]	+5.82 [2.23, 9.61]
共享提示	+29.04 [26.04, 31.84]	+38.34 [36.08, 40.43]	+37.32 [35.82, 38.86]	+21.73 [18.11, 25.42]	+34.05 [32.06, 35.95]	+36.91 [35.31, 38.49]	+7.41 [2.92, 12.11]	+5.60 [2.16, 9.66]	+4.21 [1.98, 6.33]

上行为 PRPrompt 减去对照，下行为本轮重新计算、未经多重比较校正的 95% 配对任务 bootstrap 区间。保留支持／测试重叠。

D 扩展数据集

Photo、Computers、Actor、Chameleon 与 ogbn-arxiv 沿用相同任务统计规则。下表完整列出四种方法，不与正文数据集平均。所有任务均使用原 ProG 实现；ogbn-arxiv 有 7 个名义 3-shot 任务、13 个名义 5-shot 任务的少数类不足指定数量，实际 k_c 为 1 至 4。四个不足任务的最小类别数为 1，沿用包含自身的原型损失；其余按实际类别数使用 LOO。候选池未补抽样。

表 10: 扩展数据集的 Accuracy。

数据集	Shot	冻结预训练	全量微调	共享提示	**PRPrompt**
Photo	1	47.73± 5.38	50.87± 6.88	34.10± 4.92	**60.96**± 8.88
	3	58.82± 4.41	**74.78**± 5.52	49.55± 7.34	72.96± 4.71
	5	63.09± 4.16	**80.68**± 3.32	52.46± 6.11	73.10± 5.28
Computers	1	38.13± 6.59	39.95± 9.06	33.65± 6.68	**45.60**± 8.85
	3	47.56± 3.76	**62.19**± 5.57	46.29± 6.22	57.53± 7.03
	5	52.41± 2.89	**68.79**± 4.47	51.29± 3.53	63.12± 3.12
Actor	1	20.61± 1.22	20.28± 3.19	20.20± 1.59	**20.64**± 2.30
	3	21.14± 1.46	20.87± 1.86	20.42± 1.27	**21.24**± 1.40
	5	21.12± 1.63	20.97± 1.80	20.98± 1.21	**21.34**± 1.69
Chameleon	1	21.47± 3.01	20.91± 2.12	22.22± 3.11	**22.90**± 3.53
	3	22.85± 2.73	24.00± 3.44	23.42± 2.76	**25.09**± 4.10
	5	23.71± 3.05	26.05± 3.35	24.03± 3.34	**27.29**± 3.80
ogbn-arxiv	1	10.93± 1.66	**16.28**± 3.79	10.57± 1.80	11.07± 1.67
	3	16.13± 2.03	**21.67**± 3.28	18.06± 2.22	19.97± 2.26
	5	19.54± 1.99	**24.03**± 2.57	22.52± 2.23	23.95± 1.94

本地原 ProG 实现，保留支持／测试重叠：先平均每任务 3 个训练 seed，再报告 20 个任务的均值 ± 样本标准差。**粗体**／下划线 表示同条件最优／次优；不跨条件平均。ogbn-arxiv 为名义 shot：3-shot 中 7/20、5-shot 中 13/20 个任务存在少数类支持不足，见正文说明。

表 11: 扩展数据集的 Macro-F1。

数据集	Shot	冻结预训练	全量微调	共享提示	**PRPrompt**
Photo	1	48.13± 4.86	50.48± 6.11	33.00± 4.70	**60.54**± 7.59
	3	59.13± 3.63	**73.90**± 4.73	49.41± 6.56	71.58± 3.59
	5	62.98± 3.93	**79.62**± 2.74	51.20± 5.62	72.32± 4.45
Computers	1	36.39± 5.76	38.66± 8.09	31.90± 5.77	**44.77**± 7.13
	3	44.93± 3.70	**61.51**± 5.38	43.38± 5.89	54.79± 5.46
	5	48.50± 3.17	**68.65**± 3.88	46.89± 4.24	59.44± 2.98
Actor	1	19.12± 0.98	16.16± 2.35	**19.21**± 0.98	19.00± 1.64
	3	19.23± 1.62	18.45± 1.20	19.65± 0.90	**20.06**± 0.97
	5	19.44± 1.57	19.10± 0.98	20.16± 0.93	**20.49**± 1.51
Chameleon	1	20.38± 2.89	14.27± 2.60	19.87± 3.30	**20.72**± 3.94
	3	22.04± 2.64	19.98± 3.68	21.55± 3.10	**23.32**± 3.93
	5	22.75± 3.02	23.10± 3.33	22.00± 3.37	**26.03**± 3.39
ogbn-arxiv	1	8.35± 1.08	**9.95**± 1.45	7.82± 0.98	7.92± 1.05
	3	12.77± 1.08	**14.46**± 1.25	13.08± 1.18	14.16± 1.05
	5	15.59± 1.01	16.68± 1.17	16.44± 1.08	**17.21**± 0.99

本地原 ProG 实现，保留支持／测试重叠：先平均每任务 3 个训练 seed，再报告 20 个任务的均值 ± 样本标准差。**粗体**／下划线 表示同条件最优／次优；不跨条件平均。ogbn-arxiv 为名义 shot：3-shot 中 7/20、5-shot 中 13/20 个任务存在少数类支持不足，见正文说明。

Photo 与 Computers 的 3/5-shot 中，全量微调优于 PRPrompt；ogbn-arxiv 的 1-shot 差距尤其明显。Actor 的部分路由效应区间覆盖零，1-shot Macro-F1 相对共享提示的均值差为负；Chameleon 与 ogbn-arxiv 的 1-shot 路由效应也不确定。扩展结果不支持跨图普遍优越的结论。五项完整指标、配对区间及实际支持数均保留在数据包中。