PRPrompt：面向少样本节点分类的原型路由图提示

摘要

本文提出原型路由图提示方法 PRPrompt，利用支持集原型将可学习提示分配给不同节点。在每类仅有少量标注的条件下，任务适配不仅需要学习提示内容，还需要确定提示应当作用于哪些节点。PRPrompt 从聚合节点属性构造类别参照，在保留支持集锚点的同时利用未标注图特征进行校正，并将节点与原型的关联转换为固定路由矩阵。该矩阵组合可学习类别提示，将其注入冻结图卷积编码器，最终采用原型分类。我们在 Cora、CiteSeer、PubMed 上分别评估 1、3、5-shot 设置，对各条件使用配对的支持抽样与训练种子。5-shot 下，三个数据集的 Accuracy 分别为 73.02%、66.17%、70.98%；相对同配方共享提示，原型路由在对应条件下分别带来 36.94、40.45、3.02 个百分点的提升。这些逐条件配对结果支持原型关系对提示分配的组织价值，结论限于所评估的传导式节点分类设置。

1 引言

预训练图神经网络为标注稀缺条件下的节点分类提供了已有表示。图提示通过少量任务参数完成适配，具体形式包括特征修改、提示结构和任务读出 [2, 9, 13, 14]。除选择注入位置之外，适配方法还需要回答：提示的贡献应当如何分配给不同节点？同一图中的节点在下游分类任务中具有不同的角色，因此提示分配本身就是值得研究的设计问题。

共享提示表达全图一致的调整。更灵活的方法可以学习输入相关的组合、在子图层面分配提示，或通过策略选择被提示的节点 [2, 7, 21]。这些工作说明，节点相关的分配本身并非新概念。本文关注一个更具体的问题：任务已有的少量标注样本，能否直接定义有效的路由系数，使优化集中于提示内容？支持样本提供了当前任务的类别参照，这些参照可以在适配之前构造，无需额外训练路由网络。

基于这一问题，本文提出 PRPrompt，以支持集锚定的原型作为提示分配的任务坐标。类别关联相近的节点接收相关的类别提示组合。方法首先从聚合图属性构造路由表示，以标注支持节点初始化原型，并在保留支持锚点的条件下利用未标注特征校正原型。节点与原型的关联形成固定路由矩阵，在冻结 GCN 内部组合可学习提示向量。训练仅优化提示内容，最终采用原型分类。图 1 概括了固定分配与内容学习的分工。

实验围绕两个问题组织。首先，在统一协议下，完整适配能否优于冻结预训练、全量微调和所评估的提示算子？其次，在注入位置和训练配方固定时，原型路由能否提供超出共享提示的价值？本文使用 Cora、CiteSeer、PubMed 上既有的 1、3、5-shot 配对运行回答这两个问题。每项结果均对应独立的数据集、shot 数和预训练权重。相对冻结预训练，PubMed 上的收益明显小于 Cora 与 CiteSeer，因此不能用跨数据集均值代替这些差异。

本文的主要贡献如下：

- 提出原型路由图提示构造，由支持集锚定的类别关系在提示优化前确定节点相关的分配方式。
- 给出包含 $C \times 128$ 个可学习提示参数的隐藏层实现，无需可学习路由网络。
- 提供配对适配比较与共享提示消融，逐条件报告 seed 波动及配对不确定性。

贡献聚焦原型关系对隐藏层提示的组织作用，不将原型或节点相关提示视为新的基本构件。

2 相关工作

图表示与预训练。 图卷积、邻域采样与图注意力提供了不同的节点表示构造方式 [3, 6, 15]。图自监督目标包括局部与全局信息最大化 [16]、基于增广的对比学习 [17] 以及掩码重建 [4]。预训练目标会影响下游迁移，联合节点级与图级目标也已有专门研究 [5]。本文固定每个图的预训练权重，研究下游适配，不提出新的预训练目标。

预训练与下游任务对齐。 GPPT 与 GraphPrompt 通过任务重构和提示连接预训练与下游预测 [9, 13]。All in One 通过提示向量、结构和插入规则处理多层级任务 [14]；MultiGPrompt 结合多个预训练任务及下游提示 [19]。HGPrompt 与 HetGPT 将提示学习拓展到异构图设置 [10, 18]。这些工作关注任务或图类型之间的对齐，本文则在少样本节点分类中研究更具体的问题：如何利用任务类别参照在节点间分配提示。

自适应提示分配。 GPF-plus 学习输入相关的提示组合 [2]，SUPT 在子图层面分配提示 [7]，RELIEF 联合学习节点选择与提示内容 [21]。ProNoG 面向非同配图研究条件化的节点专属提示 [20]，DAGPrompT 关注分布感知的图适配 [1]。属性引导的动态提示也已用于提升模型应对图扰动的鲁棒性 [8]。与学习分配函数的思路不同，PRPrompt 预先计算支持集条件下的原型关系，并在提示训练期间固定路由。上述工作用于界定设计空间，并非全部纳入本文的实验比较。

类别原型与评估。 Prototypical Networks 利用支持集类别代表进行预测 [12]，半监督扩展则将未标注样本用于原型构造 [11]。本文利用这些已有思想构造路由的任务参照：路由原型位于聚合属性空间，预测原型来自适配后的编码器输出。结合 ProG 对可比较图提示评估的倡议 [22]，本文明确共享编码器与拟合协议。结果描述当前统一实现，不代表各方法最佳已发表配置。

3 问题定义

给定属性图 $G = (V, E, X)$，节点数为 n，特征矩阵为 $X \in \mathbb{R}^{n\times d}$，任务类别数为 C。每个类别 c 的支持集 S_c 包含 k 个标注节点，其中 $k \in \{1, 3, 5\}$。记 $S = \bigcup_c S_c$，查询集 T 与 S 不相交。完整图结构与所有节点特征可见，拟合和超参数选择仅接收 S 内的标签；查询标签在预测封存后用于评分。

编码器采用预训练两层 GCN [6]，隐藏维度与输出维度均为 128，在 PRPrompt 中保持冻结。本文属于同图、已知类别的传导式分类：查询特征参与图聚合、原型校正和全图中心化，不属于归纳式未见类别评估。文中的一个实验条件固定数据集、shot 数、方法及预训练权重。

4 原型路由图提示

方法概览。 方法将分配与内容分开处理：首先，在聚合属性空间中用支持集锚定原型定义类别关系；其次，将这些关系转换为固定路由矩阵，为每个节点组合提示；最后，利用支持监督在冻结编码器内学习提示向量。以下各节依照这一计算顺序展开。

4.1 支持集锚定的类别参照

令 $\widehat{A} = \widetilde{D}^{-1/2}(A + I)\widetilde{D}^{-1/2}$ 为带自环的归一化邻接算子。由两跳聚合属性构造路由表示：

$$\begin{aligned} X^{(2)} &= \widehat{A}^2 X, \\ R &= \mathrm{rownorm}\Big(X^{(2)} - \mathbf{1}\,\mathrm{mean}_{v\in V}\, X_v^{(2)}\Big). \end{aligned} \tag{1}$$

其中 rownorm 对每一行进行欧氏归一化。路由使用图属性及结构，不依赖额外学习的网络。类别初始参照为

$$\mu_c^{(0)} = \frac{1}{k}\sum_{i\in S_c} R_i. \tag{2}$$

为利用未标注图信息并保留标注参照，记 $U_V = V \setminus S$。从 $\mu^{(0)}$ 开始，令 $i \in U_V$、$t = 0, 1, 2$，进行三轮固定校正：

$$a_{ic}^{(t)} = \frac{\exp(R_i^\top \,\mathrm{norm}\Big(\mu_c^{(t)}\Big)/0.05)}{\sum_{c'}\exp(R_i^\top \,\mathrm{norm}\Big(\mu_{c'}^{(t)}\Big)/0.05)}, \tag{3}$$

$$\mu_c^{(t+1)} = 0.5\mu_c^{(0)} + 0.5\frac{\sum_{i\in U_V} a_{ic}^{(t)} R_i}{\max(\sum_{i\in U_V} a_{ic}^{(t)}, 10^{-8})}. \tag{4}$$

每轮锚点始终为最初的支持原型，而不是上一轮原型。这是固定的原型构造过程，本文不赋予其期望最大化目标或收敛保证。计算不使用 U_V 中节点的标签。

4.2 从类别关系到固定路由

以校正后的原型计算温度为 $\tau_r = 0.1$ 的节点—类别关联：

$$\begin{aligned} Q_{ic} &= \mathrm{softmax}_c\Big(R_i^\top \,\mathrm{norm}\Big(\mu_c^{(3)}\Big)/\tau_r\Big), \\ B &= \widehat{A}\,(Q - \mathbf{1}\,\mathrm{mean}_{v\in V}\, Q_v). \end{aligned} \tag{5}$$

中心化表示节点类别关联相对全图平均关联的偏离，邻域聚合进一步整合相邻节点的关联模式。Q 是按行归一化的关联矩阵，B 则包含可为负的提示组合系数，不能解释为最终类别概率。每个支持集仅计算一次 B，提示训练期间保持不变。

4.3 冻结隐藏计算中的提示适配

令 H^{pre} 为原图经过 GCN 第一层得到的预激活表示，学习零初始化的矩阵 $P \in \mathbb{R}^{C\times 128}$。记 s 为 H^{pre} 的逐通道样本标准差，下界设为 10^{-6}，则注入后的隐藏表示为

$$\widetilde{H}^{\mathrm{pre}} = H^{\mathrm{pre}} + 10\,[B\tanh(P)] \odot s. \tag{6}$$

尺度向量按节点广播。经过原有 LeakyReLU 与第二层图卷积后得到 Z。支持监督优化提示内容，路由与编码器参数保持固定；零初始化使训练起点恢复冻结编码器的原始计算。Cora、CiteSeer、PubMed 分别包含 896、768、384 个可学习提示参数。

4.4 训练与预测

使用 Adam 优化提示矩阵 100 步，学习率为 0.01，权重衰减为 0：

$$\begin{aligned} \mathcal{L}(P) = \frac{1}{|S|}\sum_{i\in S} \mathrm{CE}(\ell_i(P), y_i) \\ + 10^{-3}\,\mathrm{mean}(P \odot P). \end{aligned} \tag{7}$$

支持 logits ℓ_i 采用余弦原型分类，路由消融始终使用相同的原型读出。支持集留一构造、预测归一化及温度等复现细节统一放在附录 A。

路由只需预先计算一次。在稀疏图上，两次属性聚合的复杂度为 $O(|E|d)$，每轮原型校正为 $O(nCd)$，每步提示组合 $B\tanh(P)$ 为 $O(nC\cdot 128)$，此外还包含冻结编码器的前向与反向计算。冻结权重减少可学习参数，但不会消除经过第二层卷积的梯度计算。因此本文报告参数量，不声称未经测量的运行时间优势。

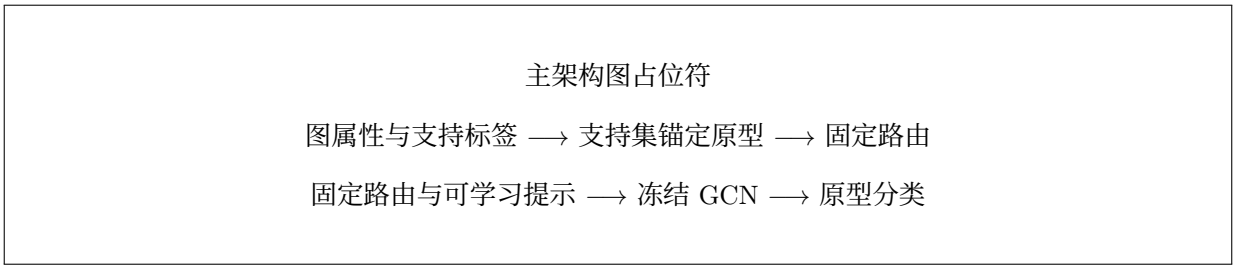


图 1: PRPrompt 总体流程。支持标签在聚合属性空间中初始化类别参照，未标注图特征用于校正参照，节点与原型的关联决定固定路由矩阵。仅类别提示向量参与优化，路由后的提示注入冻结 GCN 的第一隐藏层。拟合与选参不使用查询标签。主架构图按要求暂用占位符。

表 1: 少样本节点分类的 Accuracy。越高越好（↑）。

方法	Cora			CiteSeer			PubMed		
	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot
冻结预训练	23.17 ± 5.48	29.42 ± 3.47	33.56 ± 5.03	21.14 ± 2.87	25.29 ± 2.16	27.38 ± 2.84	55.44 ± 11.42	65.55 ± 8.11	68.37 ± 3.41
全量微调	45.41 ± 10.18	61.54 ± 6.78	67.50 ± 5.06	35.76 ± 6.80	42.22 ± 5.88	47.89 ± 4.85	48.77 ± 8.54	59.75 ± 7.97	63.96 ± 5.18
GPF	15.20 ± 3.24	24.32 ± 4.66	28.17 ± 5.54	17.10 ± 2.64	20.36 ± 2.02	21.40 ± 2.57	36.29 ± 5.79	51.28 ± 6.93	55.83 ± 4.93
GPF-plus	30.80 ± 6.64	40.21 ± 4.80	53.14 ± 5.55	21.40 ± 4.60	28.92 ± 2.68	31.82 ± 2.60	41.12 ± 6.83	57.46 ± 4.96	61.37 ± 5.32
GraphPrompt†	21.88 ± 4.62	27.75 ± 3.64	31.36 ± 3.61	19.53 ± 3.34	24.83 ± 2.77	27.66 ± 2.49	50.24 ± 12.95	62.47 ± 5.54	66.94 ± 4.09
PRPrompt	**54.59** ± 9.18	**70.76** ± 2.76	**73.02** ± 1.95	**47.12** ± 6.31	**61.20** ± 4.98	**66.17** ± 2.16	**58.70** ± 9.78	**68.66** ± 4.58	**70.98** ± 2.46

均值 ± 样本标准差（%）。每个固定条件内，先平均支持抽样内的 3 个训练 seed，再统计 20 次支持抽样。每列**粗体**为最优均值，下划线 为次优；不跨列平均。†：GraphPrompt 的统一协议适配实现。

5 实验

5.1 协议与比较方法

在 Cora、CiteSeer、PubMed 上分别评估每类 1、3、5 个支持节点。官方训练掩码定义支持池，官方测试掩码定义固定查询集。同一次支持抽样使用相同的逐类排列，取前 1、3、5 个节点构成嵌套支持集。每个条件包含 20 个支持抽样 seed 与 3 个训练 seed；各方法共享图、预训练权重及支持／查询身份。每个数据集采用项目中原始的边预测预训练权重，其预训练 seed 未记录。

主比较包含：**冻结预训练**，不添加提示并采用与 PRPrompt 相同的最终原型读出；**全量微调**，更新预训练编码器及任务读出；**GPF** 与 **GPF-plus**，在输入特征空间中适配；**GraphPrompt**†，统一节点协议下的对角读出提示实现。GPF-plus 使用 20 个提示向量。上标表示协议适配，不代表完整复现 GraphPrompt 原始的子图处理流程。这些基线遵循相应论文的提示算子思路 [2, 9]，但使用本文的编码器与选参规则。

PRPrompt 与共享提示消融使用同一固定配方。需要选参的比较方法在 3-shot 和 5-shot 下使用三个支持内折，候选为学习率 $\{0.001, 0.01\}$ 与权重衰减 $\{0, 0.0001\}$ 的四种组合。各候选拟合及最终拟合均为 100 步；1-shot 使用固定参数。因此，各方法的总优化预算并不完全相同，其余设置见附录 A。

统计单位。 在固定条件内，先对同一支持抽样下的 3 个训练 seed 求均值，再对 20 个支持抽样结果计算均值与样本标准差。不跨数据集或 shot 汇总平均表现。配对区间以支持抽样为块进行 10,000 次 bootstrap，保留方法之间的配对关系；报告固定图和权重条件下、未经多重比较校正的 95% 区间。正文报告 Accuracy 与 Macro-F1，其余指标见附录 B。

5.2 RQ1：完整适配的效果

主比较检验完整原型路由适配在相同图、权重及支持标签预算下能否改善预测。表 1 与表 2 展示全部条件，不包含跨条件平均行。

Cora 的 5-shot Accuracy 为 73.02%，冻结预训练与全量微调分别为 33.56% 和 67.50%；CiteSeer 在相同 shot 数下分别为 66.17%、27.38%、47.89%。PubMed 的冻结预训练更强：5-shot 为 68.37%，PRPrompt 为 70.98%，全量微调为 63.96%。因此，相对冻结预训练的改善在 PubMed 上明显较小，跨数据集平均会掩盖这一依赖关系。

逐条件比较中，PRPrompt 的 Accuracy 与 Macro-F1 也均高于三类提示算子。针对五个主比较方法，两项指标的配对区间全部为正。这些区间刻画当前协议下的 seed 波动，不能推出对所有图提示方法或独立图总体的普遍优势。完整配对差值见附录 C。

5.3 RQ2：原型路由的价值

核心消融将式 (6) 的 B 替换为元素均为 $1/C$ 的常数矩阵，保留提示矩阵、尺度、注入位置、优化与最终读出，移除节点相关的提示分配。常数矩阵直接用于组合，不再中心化，否则提示会被完全消除；同时保留无

表 2: 少样本节点分类的 Macro-F1。越高越好（↑）。

方法	Cora			CiteSeer			PubMed		
	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot
冻结预训练	22.51 ± 4.82	29.07 ± 3.47	33.07 ± 4.47	20.39 ± 2.62	24.32 ± 1.87	26.45 ± 2.71	53.44 ± 10.49	63.19 ± 8.60	66.27 ± 3.55
全量微调	44.38 ± 10.07	60.94 ± 6.41	66.99 ± 4.52	30.99 ± 6.30	38.43 ± 5.80	44.62 ± 4.98	44.52 ± 9.85	57.64 ± 9.26	62.53 ± 6.05
GPF	7.08 ± 2.07	21.14 ± 6.64	25.87 ± 6.19	6.78 ± 1.56	13.81 ± 5.45	15.27 ± 5.85	25.62 ± 6.56	46.88 ± 9.09	52.42 ± 6.87
GPF-plus	27.08 ± 6.92	39.31 ± 4.55	51.82 ± 5.06	12.83 ± 4.10	26.16 ± 2.85	29.46 ± 2.64	34.89 ± 8.06	54.47 ± 4.51	58.79 ± 5.19
GraphPrompt†	21.03 ± 4.36	26.98 ± 3.41	30.82 ± 3.43	18.00 ± 2.95	23.71 ± 2.39	26.72 ± 2.49	45.35 ± 10.95	59.93 ± 5.76	64.79 ± 4.02
PRPrompt	**53.34** ± 8.94	**69.38** ± 2.91	**72.04** ± 1.77	**44.26** ± 5.75	**58.19** ± 4.67	**63.03** ± 2.12	**57.37** ± 10.07	**68.21** ± 4.08	**70.39** ± 2.47

统计与强调规则同表 1；每列对应独立的数据集／ shot 条件。†：GraphPrompt 的统一协议适配实现。

表 3: 原型路由消融。提示训练配方与读出保持一致。

方法	Cora			CiteSeer			PubMed		
	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot
Accuracy (%) ↑									
冻结预训练	23.17 ± 5.48	29.42 ± 3.47	33.56 ± 5.03	21.14 ± 2.87	25.29 ± 2.16	27.38 ± 2.84	55.44 ± 11.42	65.55 ± 8.11	68.37 ± 3.41
共享提示	22.62 ± 4.41	31.70 ± 4.95	36.08 ± 4.19	20.72 ± 2.46	24.01 ± 2.70	25.73 ± 2.78	53.84 ± 10.55	62.96 ± 7.94	67.95 ± 3.11
PRPrompt	**54.59** ± 9.18	**70.76** ± 2.76	**73.02** ± 1.95	**47.12** ± 6.31	**61.20** ± 4.98	**66.17** ± 2.16	**58.70** ± 9.78	**68.66** ± 4.58	**70.98** ± 2.46
Macro-F1 (%) ↑									
冻结预训练	22.51 ± 4.82	29.07 ± 3.47	33.07 ± 4.47	20.39 ± 2.62	24.32 ± 1.87	26.45 ± 2.71	53.44 ± 10.49	63.19 ± 8.60	66.27 ± 3.55
共享提示	21.65 ± 3.66	30.25 ± 4.85	34.89 ± 4.10	19.57 ± 2.33	22.67 ± 2.46	24.55 ± 2.74	51.93 ± 9.81	60.94 ± 8.60	66.29 ± 2.87
PRPrompt	**53.34** ± 8.94	**69.38** ± 2.91	**72.04** ± 1.77	**44.26** ± 5.75	**58.19** ± 4.67	**63.03** ± 2.12	**57.37** ± 10.07	**68.21** ± 4.08	**70.39** ± 2.47

统计与强调规则同表 1；每列对应独立的数据集／ shot 条件。冻结预训练：无提示；共享提示：均匀分配；PRPrompt：原型路由。

提示的冻结预训练条件。

表 3 表明，单纯学习共享提示不足以解释完整方法的收益。5-shot 下，原型路由相对共享提示在 Cora、CiteSeer、PubMed 的 Accuracy 分别提高 36.94、40.45、3.02 个百分点，对应配对 95% 区间为 $[34.87, 39.06]$、$[39.06, 41.84]$、$[1.39, 4.51]$ 个百分点。在各个 1-shot 和 3-shot 条件中，两项主要指标的配对改善也均为正。

该比较支持完整原型路由构造相对共享提示的作用，不能将收益单独归因于原型校正、中心化或图聚合中的某一步。均匀组合虽然保留名义提示参数量，却降低有效自由度，因此也不能视为完全控制容量后对唯一路由机制的证明。

6 局限性

实验覆盖三个引文网络，每个图仅使用一份固定预训练权重，任务为同图已知类别分类。预训练 seed 未知，未估计不同预训练运行之间的波动。报告范围在实验完成后确定，因此属于描述性分析，不是新的独立确认实验；结果不支持对图分类、未见类别或任意预训练来源的推广结论。

统一协议下的提示基线及有限选参范围未必达到各方法最佳已发表成绩。基线选参产生的训练预算也不同于 PRPrompt 的固定配方。路由消融改变了有效提示容量，未区分路由内部各步骤的贡献。此外，方法利用查询特征和全图统计，缺少这类传导式信息的部署条件需另行评估。

7 结论

PRPrompt 利用支持集锚定的原型组织可学习隐藏层提示的分配，从而适配冻结图编码器。在所评估的 Cora、CiteSeer、PubMed 条件下，逐条件主比较与共享提示消融共同支持这种分配方式的价值。现有证据支持原型路由作为当前协议下的适配设计，其对其他图类型和预训练来源的普适性仍需进一步验证。

潜在影响

本文研究公开引文网络基准，不评估涉及个人的实际决策。图聚合与未标注原型校正可能传播错误，尤其当图结构或类别结构偏离所评估设置时。涉及重要后果的应用需要开展基准之外的领域评估。

参考文献

[1] Q. Chen, L. Wang, B. Zheng, and G. Song. DAGPrompT: Pushing the Limits of Graph Prompting with a Distribution-aware Graph Prompt Tuning Approach. In *Proceedings of the ACM on Web Conference 2025*, WWW '25, pages 4346–4358. ACM, Apr. 2025. doi:

10.1145/3696410.3714917. URL http://dx.doi.org/10.1145/3696410.3714917.

[2] T. Fang, Y. Zhang, Y. Yang, C. Wang, and L. Chen. Universal Prompt Tuning for Graph Neural Networks. In A. Oh, T. Naumann, A. Globerson, K. Saenko, M. Hardt, and S. Levine, editors, *Advances in Neural Information Processing Systems*, volume 36, pages 52464–52489. Curran Associates, Inc., 2023. doi: 10.52202/075280-2285. URL https://proceedings.neurips.cc/paper_files/paper/2023/file/a4a1ee071ce0fe63b83bce507c9dc4d7-Paper-Conference.pdf.

[3] W. Hamilton, Z. Ying, and J. Leskovec. Inductive Representation Learning on Large Graphs. In I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, volume 30. Curran Associates, Inc., 2017. URL https://proceedings.neurips.cc/paper_files/paper/2017/file/5dd9db5e033da9c6fb5ba83c7a7ebea9-Paper.pdf.

[4] Z. Hou, X. Liu, Y. Cen, Y. Dong, H. Yang, C. Wang, and J. Tang. GraphMAE: Self-Supervised Masked Graph Autoencoders. In *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, KDD '22, pages 594–604. ACM, Aug. 2022. doi: 10.1145/3534678.3539321. URL http://dx.doi.org/10.1145/3534678.3539321.

[5] W. Hu, B. Liu, J. Gomes, M. Zitnik, P. Liang, V. Pande, and J. Leskovec. Strategies for Pre-training Graph Neural Networks. In *International Conference on Learning Representations*, 2020. URL https://openreview.net/forum?id=HJlWWJSFDH.

[6] T. N. Kipf and M. Welling. Semi-Supervised Classification with Graph Convolutional Networks. In *International Conference on Learning Representations (ICLR)*, 2017.

[7] J. Lee, W. Yang, and J. Kang. Subgraph-level universal prompt tuning. *Information Sciences*, 749:123516, Sept. 2026. ISSN 0020-0255. doi: 10.1016/j.ins.2026.123516. URL http://dx.doi.org/10.1016/j.ins.2026.123516.

[8] Z. Liang, L. Bai, and X. Yang. Attribute-guided Dynamic Prompt Learning for Graph Neural Networks. *Proceedings of the AAAI Conference on Artificial Intelligence*, 40(28): 23442–23450, Mar. 2026. ISSN 2159-5399. doi: 10.1609/aaai.v40i28.39515. URL http://dx.doi.org/10.1609/aaai.v40i28.39515.

[9] Z. Liu, X. Yu, Y. Fang, and X. Zhang. GraphPrompt: Unifying Pre-Training and Downstream Tasks for Graph Neural Networks. In *Proceedings of the ACM Web Conference 2023*, WWW '23, pages 417–428. ACM, Apr. 2023. doi: 10.1145/3543507.3583386. URL http://dx.doi.org/10.1145/3543507.3583386.

[10] Y. Ma, N. Yan, J. Li, M. Mortazavi, and N. V. Chawla. HetGPT: Harnessing the Power of Prompt Tuning in Pre-Trained Heterogeneous Graph Neural Networks. In *Proceedings of the ACM Web Conference 2024*, WWW '24, pages 1015–1023. ACM, May 2024. doi: 10.1145/3589334.3645685. URL http://dx.doi.org/10.1145/3589334.3645685.

[11] M. Ren, E. Triantafillou, S. Ravi, J. Snell, K. Swersky, J. B. Tenenbaum, H. Larochelle, and R. S. Zemel. Meta-Learning for Semi-Supervised Few-Shot Classification, 2018. URL https://arxiv.org/abs/1803.00676.

[12] J. Snell, K. Swersky, and R. Zemel. Prototypical Networks for Few-shot Learning. In I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, volume 30. Curran Associates, Inc., 2017. URL https://proceedings.neurips.cc/paper_files/paper/2017/file/cb8da6767461f2812ae4290eac7cbc42-Paper.pdf.

[13] M. Sun, K. Zhou, X. He, Y. Wang, and X. Wang. GPPT: Graph Pre-training and Prompt Tuning to Generalize Graph Neural Networks. In *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, KDD '22, pages 1717–1727. ACM, Aug. 2022. doi: 10.1145/3534678.3539249. URL http://dx.doi.org/10.1145/3534678.3539249.

[14] X. Sun, H. Cheng, J. Li, B. Liu, and J. Guan. All in One: Multi-Task Prompting for Graph Neural Networks. In *Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, KDD '23, pages 2120–2131. ACM, Aug. 2023. doi: 10.1145/3580305.3599256. URL http://dx.doi.org/10.1145/3580305.3599256.

[15] P. Veličković, G. Cucurull, A. Casanova, A. Romero, P. Liò, and Y. Bengio. Graph Attention Networks. *International Conference on Learning Representations*, 2018. URL https://openreview.net/forum?id=rJXMpikCZ. accepted as poster.

[16] P. Veličković, W. Fedus, W. L. Hamilton, P. Liò, Y. Bengio, and R. D. Hjelm. Deep Graph Infomax. In *International Conference on Learning Representations*, 2019. URL https://openreview.net/forum?id=rklz9iAcKQ.

[17] Y. You, T. Chen, Y. Sui, T. Chen, Z. Wang, and Y. Shen. Graph Contrastive Learning with Augmentations. In H. Larochelle, M. Ranzato, R. Hadsell, M. Balcan, and H. Lin, editors, *Advances in Neural Information Processing Systems*, volume 33, pages 5812–5823. Curran Associates, Inc., 2020. URL https://proceedings.neurips.cc/paper_files/paper/2020/file/3fe230348e9a12c13120749e3f9fa4cd-Paper.pdf.

[18] X. Yu, Y. Fang, Z. Liu, and X. Zhang. HGPrompt: Bridging Homogeneous and Heterogeneous Graphs for Few-Shot Prompt Learning. *Proceedings of the AAAI Conference on Artificial Intelligence*, 38(15):16578–16586, Mar. 2024. ISSN 2159-5399. doi: 10.1609/aaai.v38i15.29596. URL http://dx.doi.org/10.1609/aaai.v38i15.29596.

[19] X. Yu, C. Zhou, Y. Fang, and X. Zhang. MultiGPrompt for Multi-Task Pre-Training and Prompting on Graphs. In *Proceedings of the ACM Web Conference 2024*, WWW '24, pages 515–526. ACM, May 2024. doi: 10.1145/3589334.3645423. URL http://dx.doi.org/10.1145/3589334.3645423.

[20] X. Yu, J. Zhang, Y. Fang, and R. Jiang. Non-Homophilic Graph Pre-Training and Prompt Learning. In *Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining V.1*, KDD '25, pages 1844–1854. ACM, July 2025. doi: 10.1145/3690624.3709219. URL http://dx.doi.org/10.1145/3690624.3709219.

[21] J. Zhu, Z. Ding, J. Yu, J. Tan, X. Li, and W. Qian. RELIEF: Reinforcement Learning Empowered Graph Feature Prompt Tuning. In *Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining V.1*, KDD '25, pages 2159–2170. ACM, July 2025. doi: 10.1145/3690624.3709252. URL http://dx.doi.org/10.1145/3690624.3709252.

[22] C. Zi, H. Zhao, X. Sun, Y. Lin, H. Cheng, and J. Li. ProG: A Graph Prompt Learning Benchmark. In A. Globerson, L. Mackey, D. Belgrave, A. Fan, U. Paquet, J. Tomczak, and C. Zhang, editors, *Advances in Neural Information Processing Systems*, volume 37, pages 95406–95437. Curran Associates, Inc., 2024. doi: 10.52202/079017-3023. URL https://proceedings.neurips.cc/paper_files/paper/2024/file/ad3e803a977f4279330c6ab7245937c6-Paper-Datasets_and_Benchmarks_Track.pdf.

A 实现与可复现细节

A.1 图预处理与固定权重

表 4 给出执行计划记录的数据维度。特征使用数据加载器的逐行归一化；官方训练与测试掩码分别定义支持池和查询集，验证集标签不用于拟合或选参。其他节点作为未标注图上下文可见。每个任务包含该图的全部类别，每类抽取指定数量的支持节点。

表 4: 数据集规模与提示参数量。

数据集	节点	特征	类别	提示参数
Cora	2,708	1,433	7	896
CiteSeer	3,327	3,703	6	768
PubMed	19,717	500	3	384

编码器由两层宽度为 128 的 GCNConv 构成，中间使用 LeakyReLU。第一层包含预训练仿射变换与图聚合，提示添加在该层输出、非线性激活之前；第二层卷积在所评估编码器中不再接额外激活。每个数据集的所有方法使用相同权重，结果记录保存权重、图及划分的哈希。预训练来源标识为 `Edgepred_Gprompt`，预训练随机种子未记录。

A.2 训练与预测细节

正文描述实际生效的前向计算。Adam 使用 $\beta_1 = 0.9$、$\beta_2 = 0.999$、$\epsilon = 10^{-8}$，学习率为 0.01，权重衰减为 0。提示正则为提示矩阵元素平方的均值乘以 10^{-3}，与优化器权重衰减不同。逐通道尺度使用分母为 $n-1$ 的样本标准差；欧氏归一化采用实现中的 10^{-12} 范数下界。训练中没有生效的蒸馏目标或查询标签目标。

对于支持损失，令 $\bar{z}_i = \mathrm{norm}(Z_i)$，$m_c = \sum_{j \in S_c} \bar{z}_j$。当 $k > 1$ 时，支持节点 i 的训练原型为

$$p_c^{(-i)} = \mathrm{norm}\left(\frac{m_c - \mathbb{I}[y_i = c]\bar{z}_i}{k - \mathbb{I}[y_i = c]} \right), \qquad \ell_{ic} = \bar{z}_i^\top p_c^{(-i)} / 0.2. \tag{8}$$

$k = 1$ 时，以包含自身的类别原型 $\mathrm{norm}(m_c/k)$ 替代 $p_c^{(-i)}$。预测时定义

$$z_i^* = \mathrm{norm}\left(Z_i - \frac{1}{n} \sum_{j \in V} Z_j \right), \qquad p_c^* = \mathrm{norm}\left(\frac{1}{k} \sum_{i \in S_c} z_i^* \right), \qquad \widehat{y}_i = \arg\max_c (z_i^*)^\top p_c^*. \tag{9}$$

将余弦 logits 除以 0.2 后取 softmax，得到五项指标使用的概率分数。训练时不使用预测阶段的输出中心化。读出是固定实现选择，不是本文的实验比较因素。

计算流程。 给定图、固定预训练权重及支持标签：

1. 归一化邻接，计算式 (1) 及第一层预激活表示。
2. 依式 (2) 初始化支持原型，执行式 (3)–(4) 三轮。
3. 依式 (5) 计算固定路由；共享提示消融则将其替换为 $B_{ic} = 1/C$。
4. 初始化 $P = 0$ 并缓存隐藏通道尺度，固定编码器与路由。
5. 重复 100 步：运行提示编码器，构造支持 logits，依式 (7) 更新 P。
6. 依式 (9) 计算最终原型分数，封存预测后再使用查询标签评分。

A.3 基线拟合与随机种子

支持抽样 seed 为 30093000 至 30093019，训练 seed 为 0、1、2。每次抽样在逐类支持池中生成有种子控制的排列，取前 k 个节点；各方法接收相同支持身份。免训练的冻结预训练条件为对齐记录而保留三个 seed 槽位，不能将其视为三次独立拟合。

可学习比较方法使用支持交叉熵。全量微调与输入提示方法包含任务读出，GraphPrompt 适配实现则对提示后的表示进行原型预测。GPF 添加共享特征向量，GPF-plus 学习 20 个特征提示及输入相关组合。它们在 1-shot 下的固定参数为学习率 0.01、权重衰减 0.0001。3-shot 和 5-shot 的三个支持内折各留出每类一个节点，按留出支持交叉熵均值选择四种候选配置，再在完整支持集上拟合所选方法；不使用额外验证标签预算。该协议控制了标注信息与最终训练步数，但没有令总选参计算量或读出参数化完全一致。

A.4 同一条件内的统计

固定数据集、shot 数、预训练权重和方法，以 a_{st} 表示支持 seed s、训练 seed t 的某项指标，计算

$$\bar{a}_s = \frac{1}{3} \sum_{t=1}^{3} a_{st}, \qquad \widehat{a} = \frac{1}{20} \sum_{s=1}^{20} \bar{a}_s, \qquad \widehat{\sigma} = \sqrt{\frac{1}{19} \sum_{s=1}^{20} (\bar{a}_s - \widehat{a})^2}. \tag{10}$$

表中报告 $100\widehat{a} \pm 100\widehat{\sigma}$，不是标准误。配对比较对 $d_s = \bar{a}_s^{\mathrm{PRPrompt}} - \bar{a}_s^{\mathrm{reference}}$ 按支持抽样块重采样，以 10,000 次重采样均值的百分位点构成 95% 区间。原区间直接复用，不作修改。不跨数据集、shot 或方法计算指标均值与平均效应。

数据包保留 Accuracy、Macro-F1、Micro-F1、宏平均 one-vs-rest ROC-AUC 和宏平均 AP。单标签多分类下 Micro-F1 与 Accuracy 相同，此处为完整性一并列出。不同支持抽样共享固定查询集，区间反映该图条件下支持选择和训练的波动，并非独立图样本的不确定性。

A.5 环境、来源与数值复核

执行计划记录复用 ProG 环境中的 Python 3.11.16、PyTorch 2.11.0+cu130 与 CUDA 13.0，逐次结果记录 CUDA 设备及拟合时间。当前提取包未给出本报告范围独立核算的

总 GPU 小时及已核实的加速器清单，本文不据此进行效率比较。

表格来源于封存的三数据集材料，包含主比较 3,240 个单元和额外共享提示 540 个单元，其中 PRPrompt 占 540 个单元。提取时核对原始指标文件校验和及配对图、权重、支持／查询身份。源数值审计显示，所选 3,780 个单元在保存表示上的读出全部精确复现，门控／前向误差通过阈值，新前向未产生查询类别变化。这些结论来自归档复核，不是本次重新运行实验；阈值通过也不等同于 CUDA 运算逐位一致。

代码与表格数据见随附仓库 https://github.com/Mes-sala/PRPrompt。已记录实验的源码版本为 `0328a2bb68f249a34c89557178b6233daf5ce20d`。论文包包含表格生成、静态检查脚本、哈希及文献来源记录。模型权重和优化器状态保留在实验服务器，不包含在本地论文包内。本文整理既有实验，没有为撰稿新增训练或 bootstrap 分析。

B 其余逐条件指标

以下表格按相同 seed 统计口径补充主比较的其余指标，每一列仍对应独立的数据集／ shot 条件。

表 5: 少样本节点分类的 Micro-F1。越高越好（↑）。

方法	Cora			CiteSeer			PubMed		
	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot
冻结预训练	23.17 ± 5.48	29.42 ± 3.47	33.56 ± 5.03	21.14 ± 2.87	25.29 ± 2.16	27.38 ± 2.84	55.44 ± 11.42	65.55 ± 8.11	68.37 ± 3.41
全量微调	45.41 ± 10.18	61.54 ± 6.78	67.50 ± 5.06	35.76 ± 6.80	42.22 ± 5.88	47.89 ± 4.85	48.77 ± 8.54	59.75 ± 7.97	63.96 ± 5.18
GPF	15.20 ± 3.24	24.32 ± 4.66	28.17 ± 5.54	17.10 ± 2.64	20.36 ± 2.02	21.40 ± 2.57	36.29 ± 5.79	51.28 ± 6.93	55.83 ± 4.93
GPF-plus	30.80 ± 6.64	40.21 ± 4.80	53.14 ± 5.55	21.40 ± 4.60	28.92 ± 2.68	31.82 ± 2.60	41.12 ± 6.83	57.46 ± 4.96	61.37 ± 5.32
GraphPrompt†	21.88 ± 4.62	27.75 ± 3.64	31.36 ± 3.61	19.53 ± 3.34	24.83 ± 2.77	27.66 ± 2.49	50.24 ± 12.95	62.47 ± 5.54	66.94 ± 4.09
PRPrompt	**54.59** ± 9.18	**70.76** ± 2.76	**73.02** ± 1.95	**47.12** ± 6.31	**61.20** ± 4.98	**66.17** ± 2.16	**58.70** ± 9.78	**68.66** ± 4.58	**70.98** ± 2.46

统计与强调规则同表 1；每列对应独立的数据集／ shot 条件。

表 6: 少样本节点分类的 Macro ROC-AUC。越高越好（↑）。

方法	Cora			CiteSeer			PubMed		
	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot
冻结预训练	62.95 ± 4.93	68.95 ± 2.99	72.36 ± 2.85	56.11 ± 3.24	60.17 ± 2.06	62.69 ± 2.35	73.87 ± 11.03	82.17 ± 6.59	84.83 ± 2.59
全量微调	81.83 ± 5.73	89.94 ± 2.35	**92.58** ± 1.26	70.97 ± 4.63	76.04 ± 3.00	79.54 ± 2.22	70.73 ± 9.76	81.00 ± 3.74	84.31 ± 2.45
GPF	53.20 ± 2.50	64.61 ± 4.25	68.65 ± 4.34	53.08 ± 1.84	55.85 ± 1.91	57.93 ± 1.77	60.13 ± 8.31	72.19 ± 4.91	74.64 ± 4.10
GPF-plus	74.73 ± 4.00	78.13 ± 2.49	85.66 ± 2.71	64.19 ± 4.07	65.37 ± 3.23	68.91 ± 2.38	68.63 ± 6.61	76.82 ± 4.24	79.98 ± 2.95
GraphPrompt†	61.93 ± 4.85	68.05 ± 3.01	71.01 ± 2.66	54.39 ± 4.21	59.99 ± 2.60	62.67 ± 2.33	70.43 ± 11.06	81.13 ± 4.42	83.57 ± 2.81
PRPrompt	**83.06** ± 5.42	**90.84** ± 1.97	92.47 ± 1.11	**74.71** ± 5.81	**82.82** ± 3.08	**85.86** ± 1.52	**76.48** ± 10.43	**86.29** ± 3.10	**87.03** ± 1.87

统计与强调规则同表 1；每列对应独立的数据集／ shot 条件。

表 7: 少样本节点分类的 Macro AP。越高越好（↑）。

方法	Cora			CiteSeer			PubMed		
	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot
冻结预训练	23.64 ± 4.26	29.20 ± 3.71	33.16 ± 4.26	21.53 ± 2.32	24.17 ± 1.59	26.46 ± 2.07	57.52 ± 10.93	67.27 ± 8.59	70.34 ± 4.13
全量微调	54.01 ± 10.10	70.20 ± 4.98	75.99 ± 3.16	38.74 ± 5.84	45.56 ± 4.79	51.03 ± 4.40	55.36 ± 10.55	67.52 ± 6.82	72.33 ± 5.00
GPF	16.64 ± 1.47	24.89 ± 3.11	28.68 ± 3.71	19.66 ± 1.43	21.40 ± 1.15	22.88 ± 1.45	43.93 ± 6.89	55.29 ± 5.93	58.42 ± 5.12
GPF-plus	40.37 ± 5.88	44.43 ± 4.09	58.84 ± 6.14	29.38 ± 4.20	30.59 ± 3.23	34.40 ± 2.70	52.61 ± 8.08	60.88 ± 5.58	65.42 ± 4.92
GraphPrompt†	23.15 ± 3.89	27.06 ± 2.89	29.92 ± 3.11	20.61 ± 2.27	23.97 ± 1.89	26.04 ± 1.65	52.39 ± 9.87	65.03 ± 5.79	68.42 ± 3.67
PRPrompt	**59.04** ± 9.07	**74.33** ± 3.38	**77.64** ± 1.87	**45.99** ± 6.79	**59.15** ± 4.80	**64.02** ± 2.66	**61.58** ± 11.39	**74.22** ± 5.19	**75.35** ± 3.34

统计与强调规则同表 1；每列对应独立的数据集／ shot 条件。

C 配对差值与不确定性

各单元格报告 PRPrompt 减去指定对照的差值，单位为百分点，并附未经多重比较校正的 95% 配对支持 bootstrap 区间。所有数值保留原配对记录，表格仅组织不同条件，不对其求平均。

表 8: PRPrompt 的 Accuracy 配对增益。差值单位为百分点。

对照方法	Cora			CiteSeer			PubMed		
	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot
冻结预训练	+31.42 [28.20, 34.59]	+41.34 [39.63, 43.04]	+39.46 [37.23, 41.61]	+25.98 [23.72, 28.21]	+35.91 [33.05, 38.39]	+38.78 [37.37, 40.18]	+3.26 [0.40, 6.22]	+3.11 [0.38, 6.27]	+2.61 [1.13, 4.22]
全量微调	+9.17 [6.58, 11.87]	+9.22 [6.75, 11.79]	+5.52 [3.73, 7.50]	+11.36 [9.57, 13.18]	+18.98 [16.78, 20.94]	+18.28 [16.22, 20.13]	+9.93 [6.77, 13.14]	+8.90 [5.89, 12.26]	+7.02 [4.96, 9.14]
GPF	+39.38 [35.60, 42.98]	+46.44 [44.21, 48.74]	+44.86 [42.52, 47.57]	+30.02 [27.04, 33.00]	+40.83 [38.11, 43.06]	+44.77 [43.32, 46.16]	+22.40 [18.82, 26.24]	+17.37 [14.16, 21.02]	+15.15 [13.30, 17.01]
GPF-plus	+23.78 [19.96, 27.47]	+30.55 [28.29, 32.52]	+19.88 [17.62, 22.16]	+25.71 [22.89, 28.45]	+32.27 [30.45, 34.03]	+34.35 [33.05, 35.65]	+17.57 [13.28, 21.86]	+11.20 [9.47, 13.11]	+9.61 [7.84, 11.49]
GraphPrompt†	+32.70 [29.19, 36.29]	+43.01 [41.38, 44.73]	+41.66 [40.03, 43.20]	+27.59 [24.97, 30.09]	+36.37 [33.26, 38.82]	+38.51 [37.14, 39.90]	+8.45 [3.60, 13.47]	+6.19 [4.04, 8.30]	+4.03 [1.94, 6.36]
共享提示	+31.96 [28.59, 35.21]	+39.06 [36.49, 41.44]	+36.94 [34.87, 39.06]	+26.40 [24.07, 28.73]	+37.18 [34.90, 39.33]	+40.45 [39.06, 41.84]	+4.85 [1.26, 8.26]	+5.69 [3.25, 8.27]	+3.02 [1.39, 4.51]

每格上行为 PRPrompt 减去对照的差值，下行为未经多重比较校正的 95% 配对支持 bootstrap 区间。数值沿用原始逐条件统计。

表 9: PRPrompt 的 Macro-F1 配对增益。差值单位为百分点。

对照方法	Cora			CiteSeer			PubMed		
	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot
冻结预训练	+30.84 [27.77, 33.84]	+40.32 [38.64, 42.08]	+38.97 [36.88, 40.99]	+23.87 [21.80, 25.77]	+33.87 [31.34, 36.14]	+36.58 [35.22, 37.95]	+3.93 [0.86, 7.00]	+5.02 [2.27, 8.44]	+4.12 [2.53, 5.91]
全量微调	+8.97 [6.40, 11.77]	+8.44 [6.12, 10.90]	+5.05 [3.34, 6.86]	+13.27 [11.17, 15.31]	+19.76 [17.45, 22.00]	+18.42 [16.07, 20.60]	+12.86 [9.39, 16.37]	+10.57 [7.08, 14.41]	+7.86 [5.54, 10.28]
GPF	+46.27 [42.36, 49.82]	+48.25 [45.22, 51.53]	+46.17 [43.71, 49.32]	+37.48 [34.93, 39.92]	+44.38 [40.82, 47.90]	+47.77 [44.95, 50.72]	+31.76 [28.23, 35.27]	+21.33 [17.31, 25.89]	+17.97 [15.46, 20.67]
GPF-plus	+26.26 [22.23, 30.20]	+30.07 [28.04, 31.97]	+20.22 [18.02, 22.39]	+31.43 [28.61, 34.12]	+32.03 [30.10, 33.81]	+33.57 [32.22, 34.87]	+22.48 [18.10, 26.98]	+13.74 [12.07, 15.56]	+11.61 [9.80, 13.53]
GraphPrompt†	+32.32 [28.93, 35.68]	+42.41 [40.61, 44.20]	+41.22 [39.64, 42.75]	+26.26 [23.90, 28.62]	+34.48 [31.80, 36.73]	+36.31 [34.99, 37.65]	+12.02 [7.33, 16.52]	+8.27 [6.21, 10.36]	+5.60 [3.49, 7.88]
共享提示	+31.70 [28.29, 35.00]	+39.13 [36.60, 41.48]	+37.15 [35.09, 39.23]	+24.69 [22.70, 26.65]	+35.52 [33.31, 37.55]	+38.48 [37.22, 39.72]	+5.44 [1.84, 9.07]	+7.27 [4.64, 10.29]	+4.10 [2.56, 5.58]

每格上行为 PRPrompt 减去对照的差值，下行为未经多重比较校正的 95% 配对支持 bootstrap 区间。数值沿用原始逐条件统计。