PRPrompt：面向少样本节点分类的原型路由图提示

摘要

本文提出原型路由图提示方法 PRPrompt，利用支持集原型将可学习提示分配给不同节点。在每类仅有少量标注的条件下，任务适配不仅需要学习提示内容，还需要确定提示应当作用于哪些节点。PRPrompt 从聚合节点属性构造类别参照，在保留支持集锚点的同时利用未标注图特征进行校正，并将节点与原型的关联转换为固定路由矩阵。该矩阵组合可学习类别提示，将其注入冻结图卷积编码器，最终采用原型分类。我们在 Cora、CiteSeer、PubMed 上分别评估 1、3、5-shot 设置，对各条件使用配对的支持抽样与训练种子。5-shot 下，三个数据集的 Accuracy 分别为 73.02%、66.17%、70.98%；相对同配方共享提示，原型路由在对应条件下分别带来 36.94、40.45、3.02 个百分点的提升。这些逐条件配对结果支持原型关系对提示分配的组织价值，结论限于所评估的传导式节点分类设置。

1 引言

预训练图神经网络为标注稀缺条件下的节点分类提供了已有表示。图提示通过少量任务参数完成适配，具体形式包括特征修改、提示结构和任务读出 [3, 10, 14, 15]。除选择注入位置之外，适配方法还需要回答：提示的贡献应当如何分配给不同节点？同一图中的节点在下游分类任务中具有不同的角色，因此提示分配本身就是值得研究的设计问题。

共享提示表达全图一致的调整。更灵活的方法可以学习输入相关的组合、在子图层面分配提示，或通过策略选择被提示的节点 [3, 8, 22]。这些工作说明，节点相关的分配本身并非新概念。本文关注一个更具体的问题：任务已有的少量标注样本，能否直接定义有效的路由系数，使优化集中于提示内容？支持样本提供了当前任务的类别参照，这些参照可以在适配之前构造，无需额外训练路由网络。

基于这一问题，本文提出 PRPrompt，以支持集锚定的原型作为提示分配的任务坐标。类别关联相近的节点接收相关的类别提示组合。方法首先从聚合图属性构造路由表示，以标注支持节点初始化原型，并在保留支持锚点的条件下利用未标注特征校正原型。节点与原型的关联形成固定路由矩阵，在冻结 GCN 内部组合可学习提示向量。训练仅优化提示内容，最终采用原型分类。图 1 概括了固定分配与内容学习的分工。

实验围绕两个问题组织。首先，完整适配在本地配对运行中相对冻结预训练和全量微调表现如何，其 Accuracy 在文献报告的提示结果中处于什么位置？其次，在注入位置和训练配方固定时，原型路由能否提供超出共享提示的价值？本地运行覆盖 Cora、CiteSeer、PubMed 的 1、3、5-shot；外部 Accuracy 取自 Chen et al. [2]，保留其原始协议。每项结果均对应独立的数据集和 shot 数。相对冻结预训练，PubMed 上的收益明显小于 Cora 与 CiteSeer。

本文的主要贡献如下：

- 提出原型路由图提示构造，由支持集锚定的类别关系在提示优化前确定节点相关的分配方式。
- 给出包含 $C \times 128$ 个可学习提示参数的隐藏层实现，无需可学习路由网络。
- 提供配对适配比较与共享提示消融，逐条件报告 seed 波动及配对不确定性。

贡献聚焦原型关系对隐藏层提示的组织作用，不将原型或节点相关提示视为新的基本构件。

2 相关工作

图表示与预训练。 图卷积、邻域采样与图注意力提供了不同的节点表示构造方式 [4, 7, 16]。图自监督目标包括局部与全局信息最大化 [17]、基于增广的对比学习 [18] 以及掩码重建 [5]。预训练目标会影响下游迁移，联合节点级与图级目标也已有专门研究 [6]。本文固定每个图的预训练权重，研究下游适配，不提出新的预训练目标。

预训练与下游任务对齐。 GPPT 与 GraphPrompt 通过任务重构和提示连接预训练与下游预测 [10, 14]。All in One 通过提示向量、结构和插入规则处理多层级任务 [15]；MultiGPrompt 结合多个预训练任务及下游提示 [20]。HGPrompt 与 HetGPT 将提示学习拓展到异构图设置 [11, 19]。这些工作关注任务或图类型之间的对齐，本文则在少样本节点分类中研究更具体的问题：如何利用任务类别参照在节点间分配提示。

自适应提示分配。 GPF-plus 学习输入相关的提示组合 [3]，SUPT 在子图层面分配提示 [8]，RELIEF 联合学习节点选择与提示内容 [22]。ProNoG 面向非同配图研究条件化的节点专属提示 [21]，DAGPrompT 关注分布感知的图适配 [1]。属性引导的动态提示也已用于提升模型应对图扰动的鲁棒性 [9]。与学习分配函数的思路不同，PRPrompt 预先计算支持集条件下的原型关系，并在提示训练期间固定路由。上述工作用于界定设计空间，并非全部纳入本文的实验比较。

类别原型与评估。 Prototypical Networks 利用支持集类别代表进行预测 [13]，半监督扩展则将未标注样本用于原型构造 [12]。本文利用这些已有思想构造路由的任务参照：路由原型位于聚合属性空间，预测原型来自适配后的编码器输出。ProG 强调评估协议的明确性 [23]。Chen et al. [2] 报告了不同预训练策略下的适配结果；本文引用其基线 Accuracy 作为文献参照，同时保留本地配对消融以检验路由价值。

3 问题定义

给定属性图 $G = (V, E, X)$，节点数为 n，特征矩阵为 $X \in \mathbb{R}^{n\times d}$，任务类别数为 C。每个类别 c 的支持集 S_c 包含 k 个标注节点，其中 $k \in \{1, 3, 5\}$。记 $S = \bigcup_c S_c$，查询集 T 与 S 不相交。完整图结构与所有节点特征可见，拟合和超参数选择仅接收 S 内的标签；查询标签在预测封存后用于评分。

编码器采用预训练两层 GCN [7]，隐藏维度与输出维度均为 128，在 PRPrompt 中保持冻结。本文属于同图、已知类别的传导式分类：查询特征参与图聚合、原型校正和全图中心化，不属于归纳式未见类别评估。文中的一个实验条件固定数据集、shot 数、方法及预训练权重。

4 原型路由图提示

方法概览。 方法将分配与内容分开处理：首先，在聚合属性空间中用支持集锚定原型定义类别关系；其次，将这些关系转换为固定路由矩阵，为每个节点组合提示；最后，利用支持监督在冻结编码器内学习提示向量。以下各节依照这一计算顺序展开。

4.1 支持集锚定的类别参照

令 $\widehat{A} = \widetilde{D}^{-1/2}(A + I)\widetilde{D}^{-1/2}$ 为带自环的归一化邻接算子。由两跳聚合属性构造路由表示：

$$\begin{aligned} X^{(2)} &= \widehat{A}^2 X, \\ R &= \mathrm{rownorm}\Big(X^{(2)} - \mathbf{1}\ \mathrm{mean}_{v\in V}\, X_v^{(2)}\Big). \end{aligned} \tag{1}$$

其中 rownorm 对每一行进行欧氏归一化。路由使用图属性及结构，不依赖额外学习的网络。类别初始参照为

$$\mu_c^{(0)} = \frac{1}{k}\sum_{i\in S_c} R_i. \tag{2}$$

为利用未标注图信息并保留标注参照，记 $U_V = V \setminus S$。从 $\mu^{(0)}$ 开始，令 $i \in U_V$、$t = 0, 1, 2$，进行三轮固定校正：

$$a_{ic}^{(t)} = \frac{\exp(R_i^\top \mathrm{norm}\Big(\mu_c^{(t)}\Big)/0.05)}{\sum_{c'}\exp(R_i^\top \mathrm{norm}\Big(\mu_{c'}^{(t)}\Big)/0.05)}, \tag{3}$$

$$\mu_c^{(t+1)} = 0.5\mu_c^{(0)} + 0.5\frac{\sum_{i\in U_V} a_{ic}^{(t)} R_i}{\max(\sum_{i\in U_V} a_{ic}^{(t)}, 10^{-8})}. \tag{4}$$

每轮锚点始终为最初的支持原型，而不是上一轮原型。这是固定的原型构造过程，本文不赋予其期望最大化目标或收敛保证。计算不使用 U_V 中节点的标签。

4.2 从类别关系到固定路由

以校正后的原型计算温度为 $\tau_r = 0.1$ 的节点—类别关联：

$$\begin{aligned} Q_{ic} &= \mathrm{softmax}_c\Big(R_i^\top \mathrm{norm}\Big(\mu_c^{(3)}\Big)/\tau_r\Big), \\ B &= \widehat{A}\,(Q - \mathbf{1}\ \mathrm{mean}_{v\in V}\, Q_v). \end{aligned} \tag{5}$$

中心化表示节点类别关联相对全图平均关联的偏离，邻域聚合进一步整合相邻节点的关联模式。Q 是按行归一化的关联矩阵，B 则包含可为负的提示组合系数，不能解释为最终类别概率。每个支持集仅计算一次 B，提示训练期间保持不变。

4.3 冻结隐藏计算中的提示适配

令 H^{pre} 为原图经过 GCN 第一层得到的预激活表示，学习零初始化的矩阵 $P \in \mathbb{R}^{C\times 128}$。记 s 为 H^{pre} 的逐通道样本标准差，下界设为 10^{-6}，则注入后的隐藏表示为

$$\widetilde{H}^{\mathrm{pre}} = H^{\mathrm{pre}} + 10\,[B\tanh(P)] \odot s. \tag{6}$$

尺度向量按节点广播。经过原有 LeakyReLU 与第二层图卷积后得到 Z。支持监督优化提示内容，路由与编码器参数保持固定；零初始化使训练起点恢复冻结编码器的原始计算。Cora、CiteSeer、PubMed 分别包含 896、768、384 个可学习提示参数。

4.4 训练与预测

使用 Adam 优化提示矩阵 100 步，学习率为 0.01，权重衰减为 0：

$$\begin{aligned} \mathcal{L}(P) = \frac{1}{|S|}\sum_{i\in S} \mathrm{CE}(\ell_i(P), y_i) \\ + 10^{-3}\,\mathrm{mean}(P \odot P). \end{aligned} \tag{7}$$

支持 logits ℓ_i 采用余弦原型分类，路由消融始终使用相同的原型读出。支持集留一构造、预测归一化及温度等复现细节统一放在附录 A。

路由只需预先计算一次。在稀疏图上，两次属性聚合的复杂度为 $O(|E|d)$，每轮原型校正为 $O(nCd)$，每步提示组合 $B\tanh(P)$ 为 $O(nC\cdot 128)$，此外还包含冻结编码器的前向与反向计算。冻结权重减少可学习参数，但不会消除经过第二层卷积的梯度计算。因此本文报告参数量，不声称未经测量的运行时间优势。

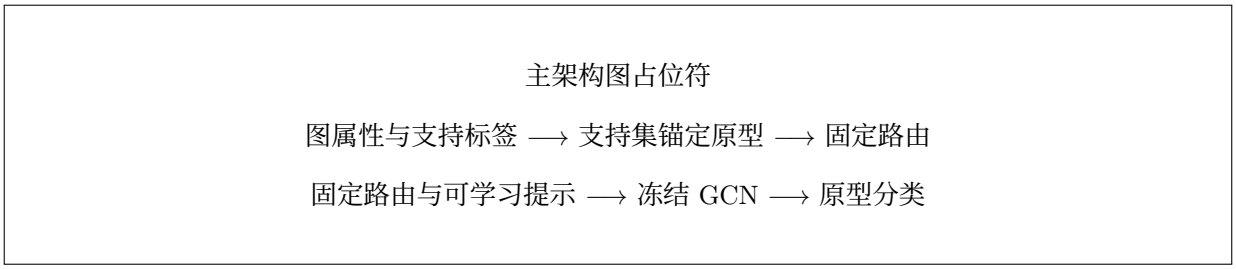


图 1: PRPrompt 总体流程。支持标签在聚合属性空间中初始化类别参照，未标注图特征用于校正参照，节点与原型的关联决定固定路由矩阵。仅类别提示向量参与优化，路由后的提示注入冻结 GCN 的第一隐藏层。拟合与选参不使用查询标签。主架构图按要求暂用占位符。

表 1: 少样本节点分类的 Accuracy。越高越好（↑）。

方法	Cora			CiteSeer			PubMed		
	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot
文献报告基线 *[2]*									
Supervised	26.56± 5.55	37.79± 9.16	50.25± 8.37	21.78± 7.32	35.18± 6.86	41.22± 6.30	39.37± 16.34	57.33± 4.64	67.88± 2.18
Fine-tuning	52.61± 1.73	51.97± 2.84	62.66± 3.55	35.05± 4.37	45.08± 2.09	39.54± 3.54	46.74± 14.89	65.40± 3.00	**70.91**± 4.87
GPPT	43.15± 9.44	43.84± 6.11	51.98± 3.43	37.26± 6.17	42.34± 8.31	45.77± 7.41	48.31± 17.72	67.43± 2.96	66.97± 3.70
Gprompt	**56.66**± 11.22	**63.78**± 5.77	**69.03**± 3.61	53.21± 10.94	60.00± 6.18	66.13± 1.64	39.74± 15.35	66.68± 3.53	67.87± 2.08
All-in-one	52.39± 10.17	48.09± 4.83	30.36± 13.48	40.41± 2.80	48.09± 8.18	27.93± 10.59	45.17± 6.45	65.79± 5.79	46.16± 15.83
GPF	38.57± 5.41	34.84± 19.83	35.43± 1.02	31.16± 8.05	25.92± 12.30	25.12± 3.01	**49.99**± 8.86	**71.20**± 2.82	68.96± 3.99
GPF-plus	55.77± 10.30	56.38± 5.37	66.22± 6.20	**59.67**± 11.87	**72.48**± 5.63	**75.73**± 2.19	46.64± 18.97	70.85± 4.03	69.59± 4.33
本地测量（协议不同）									
冻结预训练	23.17± 5.48	29.42± 3.47	33.56± 5.03	21.14± 2.87	25.29± 2.16	27.38± 2.84	55.44± 11.42	65.55± 8.11	68.37± 3.41
全量微调	45.41± 10.18	61.54± 6.78	67.50± 5.06	35.76± 6.80	42.22± 5.88	47.89± 4.85	48.77± 8.54	59.75± 7.97	63.96± 5.18
PRPrompt	**54.59**± 9.18	**70.76**± 2.76	**73.02**± 1.95	**47.12**± 6.31	**61.20**± 4.98	**66.17**± 2.16	**58.70**± 9.78	**68.66**± 4.58	**70.98**± 2.46

均值 ± 标准差（%）。文献面板取自 Chen et al. [2] 表 4–6：5 次抽样、90% 测试集、不同预训练策略中的最佳报告结果。本地面板使用固定边预测预训练权重与官方测试划分，先平均每个支持抽样的 3 个训练 seed，再统计 20 次抽样的均值／样本标准差。**粗体**／下划线 仅表示同面板同列最优／次优；不跨协议排名、配对检验或求平均。

5 实验

5.1 协议与比较方法

本地实验在 Cora、CiteSeer、PubMed 上分别评估每类 1、3、5 个支持节点。官方训练掩码定义支持池，官方测试掩码定义固定查询集。同一次支持抽样使用相同的逐类排列构成嵌套支持集。每个本地条件包含 20 个支持抽样 seed 与 3 个训练 seed；本地方法共享图、预训练权重及支持／查询身份。每个数据集采用原始的边预测预训练权重，其预训练 seed 未记录。

本地对照包含：**冻结预训练**，不添加提示并采用与 PRPrompt 相同的最终原型读出；**全量微调**，更新预训练编码器及任务读出。提示基线 Accuracy 引用 Chen et al. [2] 表 4–6 中的 GPPT、Gprompt（GraphPrompt）、All-in-one、GPF、GPF-plus，并保留原表的监督学习与微调参照，排除其 MTG 方法。原文基线结合 ProG 结果与作者复现，报告不同预训练策略中的最佳表现，但未给出各单元对应的具体策略。

文献协议。 来源论文使用 90% 测试集、5 次独立任务抽样与随机超参数搜索，主要编码器为两层、隐藏维度 128 的 GCN。这些数值与本地测试划分、权重及训练预算不匹配，因此表 1 分为文献和本地两个面板。文献均值与标准差原样保留，不重新聚合，也不进行跨面板配对检验或统一排名。原文表格仅提供 Accuracy，其他指标表仅展示本地测量。

PRPrompt 与共享提示消融使用同一固定配方。本地全量微调在 3-shot 和 5-shot 下使用三个支持内折，候选为学习率 $\{0.001, 0.01\}$ 与权重衰减 $\{0, 0.0001\}$ 的四种组合。各候选拟合及最终拟合均为 100 步；1-shot 使用固定参数。因此，本地方法的总优化预算并不完全相同，其余设置见附录 A。

统计单位。 在固定本地条件内，先对同一支持抽样下的 3 个训练 seed 求均值，再对 20 个支持抽样结果计算均值与样本标准差。不跨数据集或 shot 汇总平均表现。本地配对区间以支持抽样为块进行 10,000 次 bootstrap，报告固定图和权重条件下、未经多重比较校正的 95% 区间，仅用于冻结预训练、全量微调及共享提示对照。正文报告 Accuracy 与 Macro-F1，其余本地指标见附录 B。

表 2: 少样本节点分类的 Macro-F1。越高越好（↑）。

方法	Cora			CiteSeer			PubMed		
	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot
冻结预训练	22.51± 4.82	29.07± 3.47	33.07± 4.47	20.39± 2.62	24.32± 1.87	26.45± 2.71	53.44± 10.49	63.19± 8.60	66.27± 3.55
全量微调	44.38± 10.07	60.94± 6.41	66.99± 4.52	30.99± 6.30	38.43± 5.80	44.62± 4.98	44.52± 9.85	57.64± 9.26	62.53± 6.05
PRPrompt	**53.34**± 8.94	**69.38**± 2.91	**72.04**± 1.77	**44.26**± 5.75	**58.19**± 4.67	**63.03**± 2.12	**57.37**± 10.07	**68.21**± 4.08	**70.39**± 2.47

仅本地运行：先平均每次支持抽样的 3 个训练 seed，再报告 20 次抽样的均值 ± 样本标准差。**粗体**／下划线 表示同列同指标面板最优／次优；不跨条件平均。文献表 4–6 未报告这些基线的本指标。

表 3: 原型路由消融。提示训练配方与读出保持一致。

方法	Cora			CiteSeer			PubMed		
	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot
Accuracy (%) ↑									
冻结预训练	23.17± 5.48	29.42± 3.47	33.56± 5.03	21.14± 2.87	25.29± 2.16	27.38± 2.84	55.44± 11.42	65.55± 8.11	68.37± 3.41
共享提示	22.62± 4.41	31.70± 4.95	36.08± 4.19	20.72± 2.46	24.01± 2.70	25.73± 2.78	53.84± 10.55	62.96± 7.94	67.95± 3.11
PRPrompt	**54.59**± 9.18	**70.76**± 2.76	**73.02**± 1.95	**47.12**± 6.31	**61.20**± 4.98	**66.17**± 2.16	**58.70**± 9.78	**68.66**± 4.58	**70.98**± 2.46
Macro-F1 (%) ↑									
冻结预训练	22.51± 4.82	29.07± 3.47	33.07± 4.47	20.39± 2.62	24.32± 1.87	26.45± 2.71	53.44± 10.49	63.19± 8.60	66.27± 3.55
共享提示	21.65± 3.66	30.25± 4.85	34.89± 4.10	19.57± 2.33	22.67± 2.46	24.55± 2.74	51.93± 9.81	60.94± 8.60	66.29± 2.87
PRPrompt	**53.34**± 8.94	**69.38**± 2.91	**72.04**± 1.77	**44.26**± 5.75	**58.19**± 4.67	**63.03**± 2.12	**57.37**± 10.07	**68.21**± 4.08	**70.39**± 2.47

仅本地运行：先平均每次支持抽样的 3 个训练 seed，再报告 20 次抽样的均值 ± 样本标准差。**粗体**／下划线 表示同列同指标面板最优／次优；不跨条件平均。冻结预训练：无提示；共享提示：均匀分配；PRPrompt：原型路由。

5.2 RQ1：完整适配的效果

本地比较检验相同图、权重及支持标签预算下的适配效果。表 1 另外加入独立协议的文献参照；表 2 报告本地 Macro-F1。每列均为独立条件，不包含跨条件平均行。

Cora 的 5-shot Accuracy 为 73.02%，冻结预训练与全量微调分别为 33.56% 和 67.50%；CiteSeer 在相同 shot 数下分别为 66.17%、27.38%、47.89%。PubMed 的冻结预训练更强：5-shot 为 68.37%，PRPrompt 为 70.98%，全量微调为 63.96%。因此，相对冻结预训练的改善在 PubMed 上明显较小，跨数据集平均会掩盖这一依赖关系。

文献报告的提示结果。 引入文献数据后，不能声称 Accuracy 全面领先。CiteSeer 上 GPF-plus 在 1、3、5-shot 分别报告 59.67%、72.48%、75.73%，本地 PRPrompt 对应为 47.12%、61.20%、66.17%。Cora 的 5-shot 本地结果 73.02% 高于文献 Gprompt 的 69.03%；PubMed 的 3-shot 本地结果 68.66% 低于文献 GPF 的 71.20%。这些属于跨来源的描述性比较，不是匹配协议下的方法效应估计。路由价值由下述本地消融支持，本地配对差值见附录 C。

5.3 RQ2：原型路由的价值

核心消融将式 (6) 的 B 替换为元素均为 $1/C$ 的常数矩阵，保留提示矩阵、尺度、注入位置、优化与最终读出，移除节点相关的提示分配。常数矩阵直接用于组合，不再中心化，否则提示会被完全消除；同时保留无提示的冻结预训练条件。

表 3 表明，单纯学习共享提示不足以解释完整方法的收益。5-shot 下，原型路由相对共享提示在 Cora、CiteSeer、PubMed 的 Accuracy 分别提高 36.94、40.45、3.02 个百分点，对应配对 95% 区间为 $[34.87, 39.06]$、$[39.06, 41.84]$、$[1.39, 4.51]$ 个百分点。在各个 1-shot 和 3-shot 条件中，两项主要指标的配对改善也均为正。

该比较支持完整原型路由构造相对共享提示的作用，不能将收益单独归因于原型校正、中心化或图聚合中的某一步。均匀组合虽然保留名义提示参数量，却降低有效自由度，因此也不能视为完全控制容量后对唯一路由机制的证明。

6 局限性

实验覆盖三个引文网络，每个图仅使用一份固定预训练权重，任务为同图已知类别分类。预训练 seed 未知，未估计不同预训练运行之间的波动。报告范围在实验完成后确定，因此属于描述性分析，不是新的独立确认实验；结果不支持对图分类、未见类别或任意预训练来源的推广结论。

文献基线使用不同测试划分、5 次抽样以及跨预训练策略选择，其汇总值可提供参照，但不能相对本地固定权重运行隔离适配方法的影响，也不支持配对显著性检验。本地微调选参产生的预算也不同于 PRPrompt

的固定配方。路由消融改变了有效提示容量，未区分路由内部各步骤的贡献。此外，方法利用查询特征和全图统计，缺少这类传导式信息的部署条件需另行评估。

7 结论

PRPrompt 利用支持集锚定的原型组织可学习隐藏层提示的分配，从而适配冻结图编码器。在所评估的 Cora、CiteSeer、PubMed 条件下，逐条件主比较与共享提示消融共同支持这种分配方式的价值。现有证据支持原型路由作为当前协议下的适配设计，其对其他图类型和预训练来源的普适性仍需进一步验证。

潜在影响

本文研究公开引文网络基准，不评估涉及个人的实际决策。图聚合与未标注原型校正可能传播错误，尤其当图结构或类别结构偏离所评估设置时。涉及重要后果的应用需要开展基准之外的领域评估。

参考文献

[1] Q. Chen, L. Wang, B. Zheng, and G. Song. DAGPrompT: Pushing the Limits of Graph Prompting with a Distribution-aware Graph Prompt Tuning Approach. In *Proceedings of the ACM on Web Conference 2025*, WWW '25, pages 4346–4358. ACM, Apr. 2025. doi: 10.1145/3696410.3714917. URL http://dx.doi.org/10.1145/3696410.3714917.

[2] Y. Chen, D. Ma, S. Zhang, Y. Liu, X. Lin, X. Zhao, W. Yang, W. Chen, and C. Zhou. Message Tuning Outshines Graph Prompt Tuning: A Prismatic Space Perspective. In T. Zhang, M. Dudik, M. Jaggi, A. Agarwal, S. Li, D. Schuurmans, J. Zhu, F. Berkenkamp, H. Dong, and A. Bietti, editors, *Proceedings of the 43rd International Conference on Machine Learning*, volume 306 of *Proceedings of Machine Learning Research*, pages 16063–16104. PMLR, 06–11 Jul 2026. URL https://proceedings.mlr.press/v306/chen26cz.html.

[3] T. Fang, Y. Zhang, Y. Yang, C. Wang, and L. Chen. Universal Prompt Tuning for Graph Neural Networks. In A. Oh, T. Naumann, A. Globerson, K. Saenko, M. Hardt, and S. Levine, editors, *Advances in Neural Information Processing Systems*, volume 36, pages 52464–52489. Curran Associates, Inc., 2023. doi: 10.52202/075280-2285. URL https://proceedings.neurips.cc/paper_files/paper/2023/file/a4a1ee071ce0fe63b83bce507c9dc4d7-Paper-Conference.pdf.

[4] W. Hamilton, Z. Ying, and J. Leskovec. Inductive Representation Learning on Large Graphs. In I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, volume 30. Curran Associates, Inc., 2017. URL https://proceedings.neurips.cc/paper_files/paper/2017/file/5dd9db5e033da9c6fb5ba83c7a7ebea9-Paper.pdf.

[5] Z. Hou, X. Liu, Y. Cen, Y. Dong, H. Yang, C. Wang, and J. Tang. GraphMAE: Self-Supervised Masked Graph Autoencoders. In *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, KDD '22, pages 594–604. ACM, Aug. 2022. doi: 10.1145/3534678.3539321. URL http://dx.doi.org/10.1145/3534678.3539321.

[6] W. Hu, B. Liu, J. Gomes, M. Zitnik, P. Liang, V. Pande, and J. Leskovec. Strategies for Pre-training Graph Neural Networks. In *International Conference on Learning Representations*, 2020. URL https://openreview.net/forum?id=HJlWWJSFDH.

[7] T. N. Kipf and M. Welling. Semi-Supervised Classification with Graph Convolutional Networks. In *International Conference on Learning Representations (ICLR)*, 2017.

[8] J. Lee, W. Yang, and J. Kang. Subgraph-level universal prompt tuning. *Information Sciences*, 749:123516, Sept. 2026. ISSN 0020-0255. doi: 10.1016/j.ins.2026.123516. URL http://dx.doi.org/10.1016/j.ins.2026.123516.

[9] Z. Liang, L. Bai, and X. Yang. Attribute-guided Dynamic Prompt Learning for Graph Neural Networks. *Proceedings of the AAAI Conference on Artificial Intelligence*, 40(28): 23442–23450, Mar. 2026. ISSN 2159-5399. doi: 10.1609/aaai.v40i28.39515. URL http://dx.doi.org/10.1609/aaai.v40i28.39515.

[10] Z. Liu, X. Yu, Y. Fang, and X. Zhang. GraphPrompt: Unifying Pre-Training and Downstream Tasks for Graph Neural Networks. In *Proceedings of the ACM Web Conference 2023*, WWW '23, pages 417–428. ACM, Apr. 2023. doi: 10.1145/3543507.3583386. URL http://dx.doi.org/10.1145/3543507.3583386.

[11] Y. Ma, N. Yan, J. Li, M. Mortazavi, and N. V. Chawla. HetGPT: Harnessing the Power of Prompt Tuning in Pre-Trained Heterogeneous Graph Neural Networks. In *Proceedings of the ACM Web Conference 2024*, WWW '24, pages 1015–1023. ACM, May 2024. doi: 10.1145/3589334.3645685. URL http://dx.doi.org/10.1145/3589334.3645685.

[12] M. Ren, E. Triantafillou, S. Ravi, J. Snell, K. Swersky, J. B. Tenenbaum, H. Larochelle, and R. S. Zemel. Meta-Learning for Semi-Supervised Few-Shot Classification, 2018. URL https://arxiv.org/abs/1803.00676.

[13] J. Snell, K. Swersky, and R. Zemel. Prototypical Networks for Few-shot Learning. In I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, volume 30. Curran Associates, Inc., 2017. URL https://proceedings.neurips.cc/paper_files/paper/2017/file/cb8da6767461f2812ae4290eac7cbc42-Paper.pdf.

[14] M. Sun, K. Zhou, X. He, Y. Wang, and X. Wang. GPPT: Graph Pre-training and Prompt Tuning to Generalize Graph Neural Networks. In *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, KDD '22, pages 1717–1727. ACM, Aug. 2022. doi: 10.1145/3534678.3539249. URL http://dx.doi.org/10.1145/3534678.3539249.

[15] X. Sun, H. Cheng, J. Li, B. Liu, and J. Guan. All in One: Multi-Task Prompting for Graph Neural Networks. In *Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, KDD '23, pages 2120–2131. ACM, Aug. 2023. doi: 10.1145/3580305.3599256. URL http://dx.doi.org/10.1145/3580305.3599256.

[16] P. Veličković, G. Cucurull, A. Casanova, A. Romero, P. Liò, and Y. Bengio. Graph Attention Networks.

International Conference on Learning Representations, 2018. URL https://openreview.net/forum?id=rJXMpikCZ. accepted as poster.

[17] P. Veličković, W. Fedus, W. L. Hamilton, P. Liò, Y. Bengio, and R. D. Hjelm. Deep Graph Infomax. In *International Conference on Learning Representations*, 2019. URL https://openreview.net/forum?id=rklz9iAcKQ.

[18] Y. You, T. Chen, Y. Sui, T. Chen, Z. Wang, and Y. Shen. Graph Contrastive Learning with Augmentations. In H. Larochelle, M. Ranzato, R. Hadsell, M. Balcan, and H. Lin, editors, *Advances in Neural Information Processing Systems*, volume 33, pages 5812–5823. Curran Associates, Inc., 2020. URL https://proceedings.neurips.cc/paper_files/paper/2020/file/3fe230348e9a12c13120749e3f9fa4cd-Paper.pdf.

[19] X. Yu, Y. Fang, Z. Liu, and X. Zhang. HGPrompt: Bridging Homogeneous and Heterogeneous Graphs for Few-Shot Prompt Learning. *Proceedings of the AAAI Conference on Artificial Intelligence*, 38(15):16578–16586, Mar. 2024. ISSN 2159-5399. doi: 10.1609/aaai.v38i15.29596. URL http://dx.doi.org/10.1609/aaai.v38i15.29596.

[20] X. Yu, C. Zhou, Y. Fang, and X. Zhang. MultiGPrompt for Multi-Task Pre-Training and Prompting on Graphs. In *Proceedings of the ACM Web Conference 2024*, WWW '24, pages 515–526. ACM, May 2024. doi: 10.1145/3589334.3645423. URL http://dx.doi.org/10.1145/3589334.3645423.

[21] X. Yu, J. Zhang, Y. Fang, and R. Jiang. Non-Homophilic Graph Pre-Training and Prompt Learning. In *Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining V.1*, KDD '25, pages 1844–1854. ACM, July 2025. doi: 10.1145/3690624.3709219. URL http://dx.doi.org/10.1145/3690624.3709219.

[22] J. Zhu, Z. Ding, J. Yu, J. Tan, X. Li, and W. Qian. RELIEF: Reinforcement Learning Empowered Graph Feature Prompt Tuning. In *Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining V.1*, KDD '25, pages 2159–2170. ACM, July 2025. doi: 10.1145/3690624.3709252. URL http://dx.doi.org/10.1145/3690624.3709252.

[23] C. Zi, H. Zhao, X. Sun, Y. Lin, H. Cheng, and J. Li. ProG: A Graph Prompt Learning Benchmark. In A. Globerson, L. Mackey, D. Belgrave, A. Fan, U. Paquet, J. Tomczak, and C. Zhang, editors, *Advances in Neural Information Processing Systems*, volume 37, pages 95406–95437. Curran Associates, Inc., 2024. doi: 10.52202/079017-3023. URL https://proceedings.neurips.cc/paper_files/paper/2024/file/ad3e803a977f4279330c6ab7245937c6-Paper-Datasets_and_Benchmarks_Track.pdf.

A 实现与可复现细节

A.1 图预处理与固定权重

表 4 给出执行计划记录的数据维度。特征使用数据加载器的逐行归一化；官方训练与测试掩码分别定义支持池和查询集，验证集标签不用于拟合或选参。其他节点作为未标注图上下文可见。每个任务包含该图的全部类别，每类抽取指定数量的支持节点。

表 4: 数据集规模与提示参数量。

数据集	节点	特征	类别	提示参数
Cora	2,708	1,433	7	896
CiteSeer	3,327	3,703	6	768
PubMed	19,717	500	3	384

编码器由两层宽度为 128 的 GCNConv 构成，中间使用 LeakyReLU。第一层包含预训练仿射变换与图聚合，提示添加在该层输出、非线性激活之前；第二层卷积在所评估编码器中不再接额外激活。每个数据集的所有方法使用相同权重，结果记录保存权重、图及划分的哈希。预训练来源标识为 `Edgepred_Gprompt`，预训练随机种子未记录。

A.2 训练与预测细节

正文描述实际生效的前向计算。Adam 使用 $\beta_1 = 0.9$、$\beta_2 = 0.999$、$\epsilon = 10^{-8}$，学习率为 0.01，权重衰减为 0。提示正则为提示矩阵元素平方的均值乘以 10^{-3}，与优化器权重衰减不同。逐通道尺度使用分母为 $n-1$ 的样本标准差；欧氏归一化采用实现中的 10^{-12} 范数下界。训练中没有生效的蒸馏目标或查询标签目标。

对于支持损失，令 $\bar{z}_i = \mathrm{norm}(Z_i)$，$m_c = \sum_{j \in S_c} \bar{z}_j$。当 $k > 1$ 时，支持节点 i 的训练原型为

$$\begin{aligned} p_c^{(-i)} &= \mathrm{norm}\left(\frac{m_c - \mathbb{I}[y_i = c]\bar{z}_i}{k - \mathbb{I}[y_i = c]} \right), \\ \ell_{ic} &= \bar{z}_i^\top p_c^{(-i)} / 0.2. \end{aligned} \tag{8}$$

$k = 1$ 时，以包含自身的类别原型 $\mathrm{norm}(m_c/k)$ 替代 $p_c^{(-i)}$。预测时定义

$$\begin{aligned} z_i^* &= \mathrm{norm}\left(Z_i - \frac{1}{n} \sum_{j \in V} Z_j \right), \\ p_c^* &= \mathrm{norm}\left(\frac{1}{k} \sum_{i \in S_c} z_i^* \right), \\ \widehat{y}_i &= \arg\max_c (z_i^*)^\top p_c^*. \end{aligned} \tag{9}$$

将余弦 logits 除以 0.2 后取 softmax，得到五项指标使用的概率分数。训练时不使用预测阶段的输出中心化。读出是固定实现选择，不是本文的实验比较因素。

计算流程。 给定图、固定预训练权重及支持标签：

1. 归一化邻接，计算式 (1) 及第一层预激活表示。
2. 依式 (2) 初始化支持原型，执行式 (3)–(4) 三轮。
3. 依式 (5) 计算固定路由；共享提示消融则将其替换为 $B_{ic} = 1/C$。
4. 初始化 $P = 0$ 并缓存隐藏通道尺度，固定编码器与路由。
5. 重复 100 步：运行提示编码器，构造支持 logits，依式 (7) 更新 P。
6. 依式 (9) 计算最终原型分数，封存预测后再使用查询标签评分。

A.3 基线拟合与随机种子

支持抽样 seed 为 30093000 至 30093019，训练 seed 为 0、1、2。每次抽样在逐类支持池中生成有种子控制的排列，取

前 k 个节点；各方法接收相同支持身份。免训练的冻结预训练条件为对齐记录而保留三个 seed 槽位，不能将其视为三次独立拟合。

本地全量微调使用支持交叉熵与任务读出，1-shot 固定参数为学习率 0.01、权重衰减 0.0001。3-shot 和 5-shot 的三个支持内折各留出每类一个节点，按留出支持交叉熵均值选择四种候选配置，再在完整支持集上重新拟合；不使用额外验证标签预算。该本地协议控制标注信息与最终训练步数，但总选参计算量或读出参数化并不完全一致，也不适用于导入的文献基线。

A.4 同一条件内的统计

固定数据集、shot 数、预训练权重和方法，以 a_{st} 表示支持 seed s、训练 seed t 的某项指标，计算

$$\bar{a}_s = \frac{1}{3}\sum_{t=1}^{3} a_{st}, \qquad \widehat{a} = \frac{1}{20}\sum_{s=1}^{20} \bar{a}_s,$$
$$\widehat{\sigma} = \sqrt{\frac{1}{19}\sum_{s=1}^{20}(\bar{a}_s - \widehat{a})^2}. \tag{10}$$

本地单元报告 $100\widehat{a} \pm 100\widehat{\sigma}$，不是标准误。本地配对比较对 $d_s = \bar{a}_s^{\mathrm{PRPrompt}} - \bar{a}_s^{\mathrm{reference}}$ 按支持抽样块重采样，以 10,000 次重采样均值的百分位点构成 95% 区间，原区间直接复用。文献单元保留来源中的五次抽样均值与标准差，不套用式 (10)。不跨数据集、shot、方法或数据来源计算指标均值与平均效应。

数据包保留 Accuracy、Macro-F1、Micro-F1、宏平均 one-vs-rest ROC-AUC 和宏平均 AP。单标签多分类下 Micro-F1 与 Accuracy 相同，此处为完整性一并列出。不同支持抽样共享固定查询集，区间反映该图条件下支持选择和训练的波动，并非独立图样本的不确定性。

A.5 环境、来源与数值复核

执行计划记录复用 ProG 环境中的 Python 3.11.16、PyTorch 2.11.0+cu130 与 CUDA 13.0，逐次结果记录 CUDA 设备及拟合时间。当前提取包未给出本报告范围独立核算的总 GPU 小时及已核实的加速器清单，本文不据此进行效率比较。

本地表格数据来源于封存的三数据集材料。完整归档包含主比较 3,240 个单元和共享提示 540 个单元，其中 PRPrompt 占 540 个单元；本稿展示其中冻结预训练、全量微调、共享提示和 PRPrompt 子集。源数值审计覆盖归档的 3,780 个单元，包括配对身份核验、保存表示上的精确读出复现、前向误差阈值通过及新前向查询类别不变。这些结论来自归档复核，不是新实验；阈值通过不等同于 CUDA 运算逐位一致。

外部 Accuracy 转录自 Chen et al. [2] 表 4–6（arXiv:2606.03290v1 的 PDF 第 37–38 页），记录保留表号、页码、原始小数、来源链接与 PDF 哈希。排除 MTG 后，共记录 147 个节点分类单元，论文使用其中三个数据集的 63 个单元。来源表结合 ProG 结果与作者复现，未逐单元标注来源归属或选中的预训练策略。导入记录不含原始预测，因此不计算外部配对检验。历史本地提示结果保留归档，不用于填补文献缺失指标。

代码与表格数据见随附仓库 https://github.com/Mes-sala/PRPrompt。已记录实验的源码版本为 `0328a2bb68f249a34c89557178b6233daf5ce20d`。论文包包含表格生成、静态检查脚本、哈希及文献来源记录。模型权重和优化器状态保留在实验服务器，不包含在本地论文包内。本文整理既有实验，没有为撰稿新增训练或 bootstrap 分析。

B 其余逐条件指标

以下表格按相同 seed 统计口径补充主比较的其余指标，每一列仍对应独立的数据集／ shot 条件。

表 5: 少样本节点分类的 Micro-F1。越高越好（↑）。

方法	Cora			CiteSeer			PubMed		
	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot
冻结预训练	23.17± 5.48	29.42± 3.47	33.56± 5.03	21.14± 2.87	25.29± 2.16	27.38± 2.84	55.44± 11.42	65.55± 8.11	68.37± 3.41
全量微调	45.41± 10.18	61.54± 6.78	67.50± 5.06	35.76± 6.80	42.22± 5.88	47.89± 4.85	48.77± 8.54	59.75± 7.97	63.96± 5.18
PRPrompt	**54.59**± 9.18	**70.76**± 2.76	**73.02**± 1.95	**47.12**± 6.31	**61.20**± 4.98	**66.17**± 2.16	**58.70**± 9.78	**68.66**± 4.58	**70.98**± 2.46

仅本地运行：先平均每次支持抽样的 3 个训练 seed，再报告 20 次抽样的均值 ± 样本标准差。**粗体**／下划线 表示同列同指标面板最优／次优；不跨条件平均。文献表 4–6 未报告这些基线的本指标。

表 6: 少样本节点分类的 Macro ROC-AUC。越高越好（↑）。

方法	Cora			CiteSeer			PubMed		
	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot
冻结预训练	62.95± 4.93	68.95± 2.99	72.36± 2.85	56.11± 3.24	60.17± 2.06	62.69± 2.35	73.87± 11.03	82.17± 6.59	84.83± 2.59
全量微调	81.83± 5.73	89.94± 2.35	**92.58**± 1.26	70.97± 4.63	76.04± 3.00	79.54± 2.22	70.73± 9.76	81.00± 3.74	84.31± 2.45
PRPrompt	**83.06**± 5.42	**90.84**± 1.97	92.47± 1.11	**74.71**± 5.81	**82.82**± 3.08	**85.86**± 1.52	**76.48**± 10.43	**86.29**± 3.10	**87.03**± 1.87

仅本地运行：先平均每次支持抽样的 3 个训练 seed，再报告 20 次抽样的均值 ± 样本标准差。**粗体**／下划线 表示同列同指标面板最优／次优；不跨条件平均。文献表 4–6 未报告这些基线的本指标。

表 7: 少样本节点分类的 Macro AP。越高越好（↑）。

方法	Cora			CiteSeer			PubMed		
	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot
冻结预训练	23.64± 4.26	29.20± 3.71	33.16± 4.26	21.53± 2.32	24.17± 1.59	26.46± 2.07	57.52± 10.93	67.27± 8.59	70.34± 4.13
全量微调	54.01± 10.10	70.20± 4.98	75.99± 3.16	38.74± 5.84	45.56± 4.79	51.03± 4.40	55.36± 10.55	67.52± 6.82	72.33± 5.00
PRPrompt	**59.04**± 9.07	**74.33**± 3.38	**77.64**± 1.87	**45.99**± 6.79	**59.15**± 4.80	**64.02**± 2.66	**61.58**± 11.39	**74.22**± 5.19	**75.35**± 3.34

仅本地运行：先平均每次支持抽样的 3 个训练 seed，再报告 20 次抽样的均值 ± 样本标准差。**粗体**／下划线 表示同列同指标面板最优／次优；不跨条件平均。文献表 4–6 未报告这些基线的本指标。

C 配对差值与不确定性

各单元格报告 PRPrompt 减去本地对照的差值，单位为百分点，并附未经多重比较校正的 95% 配对支持 bootstrap 区间。所有数值保留原配对记录。文献基线没有配对运行，因此不列入本表；表格只组织条件，不对其求平均。

表 8: PRPrompt 的 Accuracy 配对增益。差值单位为百分点。

对照方法	Cora			CiteSeer			PubMed		
	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot
冻结预训练	+31.42 [28.20, 34.59]	+41.34 [39.63, 43.04]	+39.46 [37.23, 41.61]	+25.98 [23.72, 28.21]	+35.91 [33.05, 38.39]	+38.78 [37.37, 40.18]	+3.26 [0.40, 6.22]	+3.11 [0.38, 6.27]	+2.61 [1.13, 4.22]
全量微调	+9.17 [6.58, 11.87]	+9.22 [6.75, 11.79]	+5.52 [3.73, 7.50]	+11.36 [9.57, 13.18]	+18.98 [16.78, 20.94]	+18.28 [16.22, 20.13]	+9.93 [6.77, 13.14]	+8.90 [5.89, 12.26]	+7.02 [4.96, 9.14]
共享提示	+31.96 [28.59, 35.21]	+39.06 [36.49, 41.44]	+36.94 [34.87, 39.06]	+26.40 [24.07, 28.73]	+37.18 [34.90, 39.33]	+40.45 [39.06, 41.84]	+4.85 [1.26, 8.26]	+5.69 [3.25, 8.27]	+3.02 [1.39, 4.51]

每格上行为 PRPrompt 减去对照的差值，下行为未经多重比较校正的 95% 配对支持 bootstrap 区间。数值沿用原始逐条件统计。

表 9: PRPrompt 的 Macro-F1 配对增益。差值单位为百分点。

对照方法	Cora			CiteSeer			PubMed		
	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot	1-shot	3-shot	5-shot
冻结预训练	+30.84 [27.77, 33.84]	+40.32 [38.64, 42.08]	+38.97 [36.88, 40.99]	+23.87 [21.80, 25.77]	+33.87 [31.34, 36.14]	+36.58 [35.22, 37.95]	+3.93 [0.86, 7.00]	+5.02 [2.27, 8.44]	+4.12 [2.53, 5.91]
全量微调	+8.97 [6.40, 11.77]	+8.44 [6.12, 10.90]	+5.05 [3.34, 6.86]	+13.27 [11.17, 15.31]	+19.76 [17.45, 22.00]	+18.42 [16.07, 20.60]	+12.86 [9.39, 16.37]	+10.57 [7.08, 14.41]	+7.86 [5.54, 10.28]
共享提示	+31.70 [28.29, 35.00]	+39.13 [36.60, 41.48]	+37.15 [35.09, 39.23]	+24.69 [22.70, 26.65]	+35.52 [33.31, 37.55]	+38.48 [37.22, 39.72]	+5.44 [1.84, 9.07]	+7.27 [4.64, 10.29]	+4.10 [2.56, 5.58]

每格上行为 PRPrompt 减去对照的差值，下行为未经多重比较校正的 95% 配对支持 bootstrap 区间。数值沿用原始逐条件统计。